

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



BÁO CÁO MÔN HỌC THỊ GIÁC MÁY TÍNH

BÁO CÁO THỰC NGHIỆM

**DINOv2: Learning Robust Visual Features without
Supervision**

Vũ Minh Hoàng Tùng : 22022107
Lê Mai Việt Hoàng : 22022191
Tạ Đình Kiên : 22022145
Nguyễn Quốc Toàn : 22022175

HÀ NỘI - 2025

Mục lục

1	Chương 1: Tóm tắt và phân tích bài báo DINOv2	2
1.1	Bài toán (Problem)	2
1.2	Động lực nghiên cứu (Motivation)	2
1.3	Phương pháp đề xuất (Method)	2
1.4	Kết quả đạt được (Result)	3
1.5	Đóng góp chính (Contribution)	4
2	Chương 2: Thực nghiệm đánh giá DINOv2	4
2.1	Mô tả tập dữ liệu (Dataset Description)	4
2.2	Thiết lập thực nghiệm (Experiment Setup)	5
2.3	Kết quả và Trực quan hóa (Results)	5
3	Chương 3: Đánh giá và Tư duy Tích cực (Critical Thinking)	6
3.1	Điểm mạnh của phương pháp (Strengths)	6
3.2	Điểm hạn chế và Thất bại (Limitations & Failure Cases)	7
3.3	Khả năng áp dụng thực tế (Practical Applications)	7

1 Chương 1: Tóm tắt và phân tích bài báo DINOv2

1.1 Bài toán (Problem)

Trong lĩnh vực Thị giác máy tính (Computer Vision), việc học các đặc trưng hình ảnh (visual features) mạnh mẽ thường phụ thuộc nặng nề vào các tập dữ liệu khổng lồ được gán nhãn thủ công (ví dụ: ImageNet). Tuy nhiên, phương pháp Học có giám sát (Supervised Learning) này bộc lộ hai điểm yếu chí mạng: (1) Chi phí và thời gian gán nhãn vô cùng đắt đỏ; (2) Giới hạn về khả năng bao phủ sự đa dạng của thế giới thực (vấn đề phân phối đuôi dài - long-tail distribution).

Để giải quyết vấn đề này, các mô hình học từ cặp dữ liệu văn bản - hình ảnh (như CLIP hay OpenCLIP) đã ra đời và đạt được thành công lớn. Dù vậy, các mô hình này lại gặp phải rào cản về "nút thắt ngôn ngữ" (text bottleneck): Văn bản chỉ mô tả được ý nghĩa toàn cục (global semantics) của bức ảnh, nhưng hoàn toàn bất lực trong việc mô tả chi tiết các thông tin về hình học, không gian, hay ranh giới vật thể ở cấp độ pixel.

Do đó, bài toán cốt lõi mà DINOv2 đặt ra là: Làm thế nào để xây dựng một mô hình nền tảng thuần túy cho thị giác máy tính, có khả năng tự động học từ hình ảnh không nhãn (Self-Supervised Learning - SSL), nhưng xuất ra được các "đặc trưng vạn năng" (all-purpose features)? Các đặc trưng này phải hoạt động xuất sắc ở cả cấp độ toàn cục (hiểu ngữ nghĩa bức ảnh) lẫn cấp độ cục bộ (chi tiết từng pixel cho các tác vụ không gian/hình học).

1.2 Động lực nghiên cứu (Motivation)

Động lực của nhóm nghiên cứu tại Meta AI xuất phát từ sự thành công vang dội của các Mô hình Ngôn ngữ lớn (LLMs) trong lĩnh vực Xử lý Ngôn ngữ Tự nhiên (NLP). Các LLM có thể học từ lượng dữ liệu văn bản thô khổng lồ trên Internet nhờ một nhiệm vụ tự giám sát tự nhiên (dự đoán từ tiếp theo).

Tuy nhiên, trong Thị giác máy tính, việc sao chép quy mô này gặp khó khăn nghiêm trọng. Dữ liệu hình ảnh trên Internet không có cấu trúc, chứa đầy nhiễu và rất thiếu cân bằng. Nếu đưa trực tiếp hàng tỷ bức ảnh thô này vào huấn luyện, mô hình sẽ không hội tụ hoặc học phải những đặc trưng vô giá trị.

Từ đó, động lực chính của DINOv2 được xác định qua hai hướng tiếp cận đột phá:

- **Về dữ liệu:** Thay vì sử dụng dữ liệu không chọn lọc (uncurated data), cần phải có một hệ thống tự động để tinh lọc ra một tập dữ liệu "vàng" khổng lồ, đa dạng nhưng vẫn giữ được chất lượng tương đương dữ liệu có nhãn thủ công.
- **Về thuật toán:** Cần xây dựng một cơ chế học tự giám sát ổn định để huấn luyện các mạng Vision Transformer (ViT) ở quy mô hàng tỷ tham số (1B parameters) mà không bị "sụp đổ đặc trưng" (representation collapse - hiện tượng mô hình dự đoán ra cùng một đầu ra cho mọi đầu vào).

1.3 Phương pháp đề xuất (Method)

DINOv2 không đơn thuần là một thuật toán mới, mà là một hệ thống (pipeline) hoàn chỉnh kết hợp giữa kỹ nghệ dữ liệu và tối ưu hóa huấn luyện. Phương pháp được chia thành các trụ cột chính:

a. Quy trình Giám tuyển Dữ liệu (Data Curation Pipeline):

Nhóm tác giả không gán nhân thủ công mà tự động hóa việc xây dựng tập dữ liệu thông qua cơ chế Truy xuất hình ảnh (Image Retrieval). Cụ thể:

- Họ sử dụng một tập dữ liệu nhỏ đã được giám tuyển chất lượng cao (Curated data) làm "hạt giống".
- Trích xuất đặc trưng của tập hạt giống này và so sánh độ tương đồng cosine (Cosine similarity) với hàng tỷ bức ảnh thô cào được từ web.
- Chỉ những bức ảnh từ web có độ tương đồng cao với tập hạt giống mới được giữ lại. Kết quả là sự ra đời của LVD-142M – tập dữ liệu gồm 142 triệu hình ảnh chất lượng cao, cân bằng về mặt phân phối mà không cần bất kỳ sự can thiệp nào của con người.

b. Mục tiêu Huấn luyện Kép (Dual Training Objective):

Thuật toán của DINOv2 là sự hợp nhất của hai phương pháp SSL tiên tiến, học theo kiến trúc Student-Teacher:

- **Học đặc trưng toàn cục (DINO - Self-Distillation):** Mạng Student học cách dự đoán lại biểu diễn toàn cục (global embedding) của mạng Teacher. Trọng số của Teacher được cập nhật từ từ thông qua Trung bình động theo cấp số nhân (EMA - Exponential Moving Average) từ trọng số của Student.
- **Học đặc trưng cục bộ (iBOT - Masked Image Modeling):** Tương tự như trò chơi điền vào chỗ trống, mô hình sẽ bị che đi (mask) một số mảnh ảnh (patches). Mạng Student buộc phải khôi phục lại các đặc trưng của những mảnh bị che này dựa trên thông tin từ các mảnh lân cận. Điều này ép mô hình phải hiểu sâu về cấu trúc không gian.

c. Các kỹ thuật ổn định mô hình (Regularization & Engineering):

Để huấn luyện thành công mạng ViT-g (1 tỷ tham số), nhóm nghiên cứu áp dụng các công cụ toán học tối tân để tránh mô hình bị sụp đổ:

- **Sử dụng Sinkhorn-Knopp Centering:** Tối ưu hóa việc phân cụm các đặc trưng.
- **Sử dụng KoLeo Regularizer:** Hàm phạt giúp các vector đặc trưng phân bố đều đặn và cách xa nhau trong không gian biểu diễn (representation space).
- **Tăng độ phân giải ở giai đoạn cuối (High-resolution fine-tuning):** Ở những epoch cuối, mô hình được huấn luyện với ảnh đầu vào có độ phân giải cao hơn để làm mịn các đặc trưng ở cấp độ pixel.

1.4 Kết quả đạt được (Result)

DINOv2 đã tạo ra một cơn địa chấn trong cộng đồng nghiên cứu khi chứng minh rằng các đặc trưng học tự giám sát thuần túy có thể đánh bại các mô hình có giám sát truyền thống.

- **Đặc trưng "Out-of-the-box" mạnh mẽ:** Không cần phải tinh chỉnh lại toàn bộ mạng (fine-tuning) cho từng bài toán mới. Chỉ cần đóng băng (freeze) bộ trọng số của DINOv2 và thêm một lớp phân loại tuyến tính đơn giản (Linear Probing) hoặc dùng thuật toán k-NN, mô hình đã đạt kết quả SOTA (State-of-the-Art) trên tập ImageNet-1K.

- **Thống trị các tác vụ dự đoán dày đặc (Dense Tasks):** Đây là điểm vượt trội nhất của DINOv2 so với mô hình CLIP. DINOv2 cho ra kết quả cực kỳ chính xác trong các bài toán yêu cầu hiểu chi tiết hình học như: Phân đoạn ngữ nghĩa (Semantic Segmentation) và Ước lượng chiều sâu đơn mục kính (Monocular Depth Estimation).
- **Bảo toàn cấu trúc không gian xuất sắc:** Các thực thể (objects) trong ảnh được mô hình nhận diện với ranh giới cực kỳ sắc nét. Mô hình thậm chí có khả năng so khớp (matching) các bộ phận tương đồng của một vật thể ở nhiều góc chụp khác nhau mà không cần được dạy trước.

1.5 Đóng góp chính (Contribution)

Bài báo DINOv2 mang lại 3 đóng góp mang tính nền tảng cho tương lai của Computer Vision:

- **Tiên phong cho "Thị giác thuần túy":** Đập tan định kiến cho rằng phải cần đến văn bản (text-supervision) mới tạo ra được mô hình nền tảng. DINOv2 chứng minh rằng hình ảnh tự bản thân nó chứa đủ lượng thông tin để mô hình học được các cấu trúc sâu sắc nhất.
- **Định hình lại cách xây dựng Dữ liệu lớn:** Đề xuất một quy trình chuẩn mực, tự động và mã nguồn mở để lọc dữ liệu hình ảnh khổng lồ (tạo ra tập LVD-142M), giải quyết bài toán thiếu hụt dữ liệu chất lượng cao trong kỷ nguyên SSL.
- **Dân chủ hóa AI thông qua Mã nguồn mở:** Meta đã công bố toàn bộ trọng số của các phiên bản DINOv2 (ViT-S, ViT-B, ViT-L, ViT-g). Ngay lập tức, DINOv2 đã trở thành "xương sống" (backbone) tiêu chuẩn được cộng đồng sử dụng rộng rãi để trích xuất đặc trưng cho vô số các nghiên cứu ứng dụng từ y tế, nông nghiệp đến xe tự lái.

2 Chương 2: Thực nghiệm đánh giá DINOv2

2.1 Mô tả tập dữ liệu (Dataset Description)

Để kiểm chứng khả năng trích xuất đặc trưng của DINOv2 trong một miền dữ liệu hẹp, nhóm quyết định sử dụng bộ dữ liệu y tế **SkinCancerMNIST (HAM10000)**. Đây là một tập dữ liệu ảnh da liễu với độ khó cao do các bệnh lý về da thường có màu sắc và kết cấu bề mặt rất giống nhau.

- **Số lượng:** 10,015 hình ảnh đa dạng về tổn thương da.
- **Phân loại:** 7 lớp bệnh lý (Ví dụ: Melanoma, Basal cell carcinoma, v.v.).
- **Thách thức:** Tập dữ liệu bị mất cân bằng nghiêm trọng (imbalanced), đòi hỏi mô hình phải có khả năng hiểu các đặc trưng tinh vi thay vì chỉ học vẹt theo tần suất xuất hiện.


2.2 Thiết lập thực nghiệm (Experiment Setup)

Thực nghiệm được triển khai với cấu hình như sau:

- **Mô hình kiểm chứng (Baseline):** ResNet50 (Huấn luyện có giám sát toàn bộ mạng) và CLIP ViT-B/32 (Linear Probe).
- **Mô hình DINOv2:** Sử dụng phiên bản `dinov2_vitb14` với toàn bộ trọng số (backbone) được đóng băng (freeze). Chỉ có một lớp phân loại tuyến tính (Linear Head) duy nhất được cập nhật trọng số.
- **Siêu tham số (Hyperparameters):**
 - Batch size: 32
 - Số Epochs: 10
 - Tốc độ học (Learning Rate): 10^{-3} với Adam Optimizer
 - Loss Function: CrossEntropy Loss

2.3 Kết quả và Trực quan hóa (Results)


Sau 10 Epochs huấn luyện, các mô hình hội tụ và cho ra kết quả được thể hiện qua các đồ thị dưới đây.



Hình 1: Tốc độ hội tụ (Validation Loss) của các mô hình

Như quan sát trên Hình 1, mô hình DINOv2 (đường màu đỏ) cho thấy tốc độ hội tụ rất nhanh ngay từ những epoch đầu tiên. Điều này chứng tỏ bộ đặc trưng ban đầu mà DINOv2 cung cấp đã chứa sẵn hàm lượng thông tin cực kỳ cao, giúp lớp phân loại (Linear Head) dễ dàng tìm được ranh giới quyết định. Ngược lại, ResNet50 mất nhiều thời gian hơn để tinh chỉnh toàn bộ các tầng chập (convolutional layers).

Bảng 1 trình bày kết quả chi tiết thu được sau quá trình kiểm thử trên tập dữ liệu chưa từng thấy (Test set).



Hình 2: So sánh hiệu năng (Accuracy và F1-Score) trên tập Test

Mô hình	Phương pháp	Test Accuracy (%)	Test F1-Score (%)
DINOv2	Linear Probing	80.48	78.91
ResNet50	Supervised Fine-tuning	79.43	78.57
CLIP	Linear Probing	79.33	78.19

Bảng 1: Bảng tổng hợp kết quả hiệu năng của các mô hình

Về mặt hiệu năng tổng thể (Hình 2 và Bảng 1), DINOv2 đạt được độ chính xác (Accuracy: 80.48%) và điểm F1-Score (78.91%) cao nhất, vượt qua cả CLIP và mô hình tham chiếu ResNet50. Mặc dù CLIP là mô hình nền tảng mạnh mẽ (Accuracy đạt 79.33%), nhưng do được học qua sự ghép nối (alignment) với văn bản, nó có xu hướng nắm bắt các khái niệm tổng quát (global concepts) thay vì các chi tiết cấu trúc cục bộ tinh vi trên da như DINOv2. ResNet50 (Supervised) cũng đạt kết quả tương đối tốt (79.43%) do được huấn luyện tinh chỉnh toàn bộ, nhưng lại tốn kém tài nguyên và thời gian tính toán hơn rất nhiều so với phương pháp Linear Probe của DINOv2 (vốn chỉ cần cập nhật trọng số của một lớp phân loại duy nhất).

3 Chương 3: Đánh giá và Tư duy Tích cực (Critical Thinking)

3.1 Điểm mạnh của phương pháp (Strengths)

Dựa trên kết quả thực nghiệm với tập dữ liệu y tế SkinCancerMNIST, có thể rút ra những điểm mạnh cốt lõi của DINOv2:

- **Đặc trưng "Out-of-the-box" sâu sắc:** Khác với các phương pháp SSL cũ, DINOv2

cung cấp một bộ trọng số cực kỳ chất lượng. Ngay cả khi chưa hề nhìn thấy ảnh nội soi da liễu trong quá trình huấn luyện, mô hình vẫn trích xuất được những vector đặc trưng có khả năng phân tách cao. Điều này giúp lớp Linear Probe hội tụ nhanh chóng và đạt độ chính xác gần tương đương với mạng ResNet50 được huấn luyện có giám sát từ đầu.

- **Vượt qua "Nút thắt ngôn ngữ":** So với CLIP (phụ thuộc vào mô tả văn bản), DINOv2 chứng tỏ sự ưu việt trong các bài toán y tế. Ảnh da liễu chứa những chi tiết cực kỳ tinh vi về kết cấu (texture) và hình học (geometry) mà ngôn ngữ tự nhiên không thể miêu tả hết (ví dụ: "viền bất đối xứng", "màu sắc không đồng đều li ti"). DINOv2 học thuần túy từ hình ảnh nên không bị bỏ sót các thông tin cục bộ này.

3.2 Điểm hạn chế và Thất bại (Limitations & Failure Cases)

Dù mạnh mẽ, phương pháp vẫn tồn tại những rào cản nhất định:

- **Chi phí huấn luyện ban đầu khổng lồ:** Để có được các đặc trưng "vạn năng", Meta AI đã phải dùng đến hàng ngàn GPU để huấn luyện trên 142 triệu hình ảnh. Do đó, việc tự xây dựng một mô hình tương tự DINOv2 từ đầu đối với các nhóm nghiên cứu nhỏ là bất khả thi.
- **Độ nhạy cảm với dữ liệu ngoài phân phối (Out-of-Distribution):** Mặc dù DINOv2 khái quát hóa rất tốt, nhưng trong các trường hợp cực đoan như ảnh y tế chụp dưới ánh sáng quá yếu hoặc ảnh siêu âm mờ, cấu trúc không gian bị biến dạng hoàn toàn, các đặc trưng của DINOv2 có thể mất tác dụng và dẫn tới phân loại sai (Failure cases).
- **Thiếu khả năng giải thích (Interpretability):** Trong y tế, việc hiểu tại sao mô hình đưa ra quyết định là tối quan trọng. DINOv2 cung cấp các vector đặc trưng dày đặc nhưng lại khó để bác sĩ hiểu được lớp Linear Probe đang tập trung vào vùng nào của tổn thương da nếu không sử dụng thêm các công cụ như Grad-CAM hoặc Attention Maps.

3.3 Khả năng áp dụng thực tế (Practical Applications)

Từ bài báo DINOv2 và thực nghiệm trên SkinCancerMNIST, tính ứng dụng thực tế của mô hình là rất lớn:

- **Hỗ trợ Chẩn đoán Y khoa (Medical Imaging):** Dữ liệu y tế (X-quang, MRI, nội soi) rất phong phú nhưng dữ liệu được gán nhãn bởi chuyên gia lại cực kỳ khan hiếm. DINOv2 mở ra tiềm năng sử dụng trực tiếp các ảnh không nhãn để tạo nền tảng, sau đó chỉ cần một lượng rất nhỏ ảnh có nhãn để huấn luyện lớp Linear Head.
- **Nông nghiệp thông minh:** Trích xuất đặc trưng của bề mặt lá cây để phát hiện sâu bệnh, phân loại các loại cỏ dại mà không cần tốn công sức thu thập hàng vạn ảnh gán nhãn cho từng khu vực địa lý.
- **Thị giác Robot và Xe tự lái:** Nhờ khả năng phân đoạn ngữ nghĩa (Semantic Segmentation) và bảo toàn cấu trúc không gian cực tốt, DINOv2 có thể đóng vai

trò là "đôi mắt" cốt lõi giúp xe tự lái hoặc robot hiểu sâu sắc về độ sâu và hình học của môi trường xung quanh.