

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



BÁO CÁO MÔN HỌC THỊ GIÁC MÁY TÍNH

BÁO CÁO THỰC NGHIỆM

**DINOv2: Learning Robust Visual Features without
Supervision**

Vũ Minh Hoàng Tùng : 22022107
Lê Mai Việt Hoàng : 22022191
Tạ Đình Kiên : 22022145
Nguyễn Quốc Toàn : 22022175

HÀ NỘI - 2025

Tóm tắt

Tóm tắt dự án

Báo cáo này trình bày nghiên cứu và thực nghiệm về mô hình **DINOv2** — một phương pháp học biểu diễn thị giác tự giám sát (self-supervised) tiên tiến được đề xuất bởi Meta AI Research. DINOv2 kế thừa và mở rộng từ DINO, kết hợp các kỹ thuật chất lọc tri thức tự giám sát, học tương phản (iBOT), và điều chuẩn phân phối đặc trưng (KoLeo) trên tập dữ liệu hình ảnh quy mô lớn được tuyển chọn kỹ lưỡng. Mô hình đạt được các đặc trưng thị giác mạnh mẽ, tổng quát hóa tốt trên nhiều tác vụ downstream mà không cần nhãn dữ liệu trong quá trình huấn luyện.

Trong dự án này, nhóm đã nghiên cứu kiến trúc Vision Transformer (ViT) nền tảng, phân tích pipeline huấn luyện tự giám sát của DINOv2, đồng thời tiến hành thực nghiệm đánh giá khả năng của mô hình trên các bài toán phân loại ảnh, phân đoạn ngữ nghĩa và trích xuất đặc trưng. Kết quả thực nghiệm cho thấy DINOv2 tạo ra các đặc trưng có chất lượng cao, cạnh tranh hoặc vượt trội so với các phương pháp có giám sát trên nhiều benchmark tiêu chuẩn.

Bảng đánh giá đóng góp thành viên

STT	Họ và tên	MSSV	Đóng góp	Nhiệm vụ chính
1	Vũ Minh Hoàng Tùng	22022107	25%	Nghiên cứu kiến trúc ViT, viết Chương 1
2	Lê Mai Việt Hoàng	22022191	25%	Phân tích pipeline DINOv2, viết Chương 2
3	Tạ Đình Kiên	22022145	25%	Triển khai thực nghiệm, viết Chương 3
4	Nguyễn Quốc Toàn	22022175	25%	Đánh giá kết quả, tổng hợp báo cáo
Tổng cộng			100%	

Bảng đánh giá mức độ đóng góp của từng thành viên

Mục lục

Tóm tắt	1
1 BÀI TOÁN VÀ ĐỘNG LỰC CỦA BÀI BÁO DINOv2	6
1.1 Bài toán	6
1.1.1 Bối cảnh: dữ liệu thị giác lớn nhưng thiếu nhãn và nhu cầu mô hình nền tảng	6
1.1.2 Ý nghĩa của Self-Supervised Learning và Foundation Model	7
1.1.3 Hạn chế của các hướng tiếp cận hiện tại	7
1.1.4 Phát biểu bài toán	8
1.2 Động lực nghiên cứu	8
1.2.1 Tiềm năng chưa được khai thác của self-supervised learning . . .	8
1.2.2 Ba động lực chính dẫn đến DINOv2	9
1.2.3 Ý nghĩa của bài toán	10
1.2.4 Vị trí của DINOv2 trong tiến trình phát triển SSL	10
1.3 Phương pháp	10
1.4 Kết quả	16
1.4.1 Tổng quan kết quả	16
1.4.2 Kết quả trên ImageNet-1k	16
1.4.3 Robustness và domain generalization	16
1.4.4 Phân loại ảnh/video ngoài ImageNet	16
1.4.5 Dense recognition: segmentation và depth estimation	17
1.4.6 Kết quả định tính	17
1.4.7 Kết luận từ kết quả	18
1.5 Đóng góp	18
1.5.1 Đóng góp tổng quát	18
1.5.2 Các đóng góp chính	19
1.5.3 Đóng góp về mặt khoa học	19
1.5.4 Đóng góp về mặt thực tiễn	20
1.5.5 Hạn chế và hướng mở rộng	20
1.5.6 Tóm tắt cuối cùng	20
2 THỰC NGHIỆM ĐÁNH GIÁ DINOv2	23
2.1 Bài toán Phân loại ảnh	23
2.1.1 Mô tả chi tiết tập dữ liệu SkinCancerMNIST (HAM10000)	23
2.1.2 Thiết lập thực nghiệm và Cấu hình so sánh (ViT và DINOv2) . .	24
2.1.3 Kết quả và Đánh giá	24
2.1.4 Phân tích Ma trận Nhầm lẫn	25
2.2 Bài toán Phân đoạn ảnh Zero-Shot	26

2.2.1	Mô tả tập dữ liệu Oxford-IIIT Pet (Trimap)	26
2.2.2	Thiết lập thực nghiệm	27
2.2.3	Kết quả định lượng	28
2.2.4	Phân tích định tính	30
2.2.5	Kết luận §2.2	31
3	ĐÁNH GIÁ VÀ TƯ DUY TÍCH CỰC	33
3.1	Đánh giá thực nghiệm Phân loại ảnh (§2.1)	33
3.1.1	Điểm mạnh của phương pháp	33
3.1.2	Điểm hạn chế và Thất bại	33
3.2	Đánh giá thực nghiệm Phân đoạn ảnh Zero-Shot (§2.2)	34
3.2.1	Điểm mạnh của phương pháp	34
3.2.2	Điểm hạn chế và Thất bại	34
3.3	Khả năng áp dụng thực tế	35

Danh mục hình ảnh

1.1	Quy trình xử lý dữ liệu của DINOv2: dữ liệu ảnh thô được embedding, khử trùng lặp và truy xuất theo độ tương đồng để tạo tập dữ liệu curated LVD-142M.	8
1.2	PCA visualization của patch features: các vùng tương ứng giữa những ảnh liên quan được mô hình nhận ra dù thay đổi tư thế, phong cách hoặc đối tượng.	9
1.3	Hiệu năng khi scale mô hình: DINOv2 cải thiện mạnh so với các SSL model trước đó và đạt mức cạnh tranh với weakly-supervised features trên nhiều nhóm tác vụ.	10
1.4	Ảnh hưởng của độ phân giải: huấn luyện 224 rồi chuyển sang độ phân giải cao trong giai đoạn ngắn cuối giúp cải thiện cả ImageNet-1k và ADE-20K với chi phí thấp hơn.	15
1.5	Hiệu quả của distillation: ViT-L/14 distilled từ ViT-g/14 vượt ViT-L/14 train từ scratch trên nhiều benchmark.	16
1.6	Kết quả định tính về segmentation và depth estimation với linear classifier trên frozen features.	21
1.7	Ví dụ ngoài phân phối: DINOv2 vẫn cho kết quả tương đối ổn trên tranh, ký họa và ảnh thuộc miền khác.	22
2.1	Tốc độ hội tụ (Validation Loss) của các mô hình trong quá trình huấn luyện	25
2.2	So sánh hiệu năng (Accuracy và F1-Score) trên tập Test	26
2.3	Ma trận nhầm lẫn (Confusion Matrix) của mô hình DINOv2 trên tập Test	27
2.4	Ma trận nhầm lẫn (Confusion Matrix) của mô hình ViT-B/16 trên tập Test	28
2.5	So sánh mIoU giữa ba backbone và hai phương pháp training-free.	29
2.6	IoU theo từng class (pet / background / border) cho phương pháp Prototype.	30
2.7	So sánh định tính: Original Ground truth DINOv2-B Prototype DINOv2-B Clustering ViT-B/16 Prototype.	31
2.8	KMeans ($k = 3$) trên patch features — DINOv2 (SSL) phân biệt foreground/background rõ rệt hơn ViT-B/16 ImageNet.	32

Danh mục bảng

1.1	So sánh nguồn dữ liệu pretraining: LVD-142M cho kết quả tốt hơn dữ liệu uncurated và thường vượt ImageNet-22k trên nhiều benchmark ngoài ImageNet.	9
1.2	Tiến trình phát triển SSL và vị trí của DINOv2.	10
1.3	Ablation của KoLeo loss và masked image modeling: KoLeo cải thiện retrieval, còn MIM/iBOT giúp cải thiện tác vụ dense prediction như segmentation.	13
1.4	Ablation recipe huấn luyện từ iBOT đến DINOv2. Các thay đổi được thêm tuần tự để cải thiện chất lượng đặc trưng và độ ổn định khi scale.	14
1.5	Linear evaluation trên ImageNet-1k: DINOv2 ViT-g/14 đạt 86.5% linear accuracy và cạnh tranh trực tiếp với các mô hình weakly-supervised/text-guided.	17
1.6	Fine-tuning trên ImageNet-1k: DINOv2 vẫn cải thiện khi fine-tune, nhưng mức tăng vừa phải cho thấy frozen features đã rất mạnh.	18
1.7	Domain generalization: DINOv2 cải thiện mạnh so với SSL trước đó, đặc biệt trên ImageNet-A và ImageNet-C.	18
1.8	Linear evaluation trên các benchmark phân loại ảnh và video: DINOv2 tổng quát tốt sang fine-grained classification và video understanding.	19
1.9	Semantic segmentation với frozen features: DINOv2 đạt kết quả mạnh trên ADE20K, CityScapes và Pascal VOC.	19
1.10	Depth estimation với frozen features: DINOv2 cải thiện rõ rệt so với OpenCLIP, MAE, DINO và iBOT; chỉ số thấp hơn là tốt hơn.	20
1.11	Tóm tắt các đóng góp chính của DINOv2.	22
2.1	Bảng tổng hợp kết quả hiệu năng của các mô hình	25
2.2	Kết quả zero-shot segmentation trên 150 ảnh test của Oxford-IIIT Pet (10 ảnh reference).	29

Chương 1

BÀI TOÁN VÀ ĐỘNG LỰC CỦA BÀI BÁO DINOv2

1.1 Bài toán

1.1.1 Bối cảnh: dữ liệu thị giác lớn nhưng thiếu nhãn và nhu cầu mô hình nền tảng

Bối cảnh của DINOv2 xuất phát từ một thực tế cốt lõi: lượng ảnh có sẵn trên internet là khổng lồ và tăng không ngừng, nhưng phần lớn trong số đó **không có nhãn** hoặc không có caption chất lượng cao. Việc gán nhãn thủ công cho dữ liệu thị giác rất tốn kém, đòi hỏi nhiều công sức con người và gần như không thể mở rộng theo kịp tốc độ sinh dữ liệu. Hệ quả là một nghịch lý: dữ liệu thì dư thừa, nhưng tín hiệu giám sát (nhãn) lại khan hiếm. Điều này đặt ra nhu cầu học biểu diễn thị giác **trực tiếp từ ảnh thô**, không phụ thuộc vào nhãn người gán hay văn bản đi kèm.

Trong xử lý ngôn ngữ tự nhiên (NLP), một bước ngoặt đã diễn ra khi người ta pretraining mô hình trên kho văn bản thô khổng lồ bằng các pretext objective (như language modeling) *không cần giám sát*, từ đó tạo ra các biểu diễn tổng quát, độc lập với tác vụ (task-agnostic) và có thể dùng trực tiếp “as-is”. Những mô hình như vậy được gọi là *mô hình nền tảng* (foundation model) [7]. Một câu hỏi tự nhiên đặt ra cho thị giác máy tính: liệu có thể xây dựng một mô hình nền tảng tương tự cho ảnh, tức một backbone học từ lượng lớn ảnh không nhãn và sinh ra *general-purpose visual features* dùng được ngay (out-of-the-box) cho nhiều tác vụ khác nhau hay không? Đây chính là động lực bối cảnh mà DINOv2 hướng tới.

Trong các hệ thống thị giác máy tính, đặc trưng hình ảnh (visual features) đóng vai trò trung tâm: chúng là biểu diễn số học của nội dung ảnh và là đầu vào cho các tác vụ như phân loại ảnh, phát hiện vật thể, phân đoạn ngữ nghĩa, ước lượng độ sâu hoặc truy xuất ảnh. Vì vậy, chất lượng của visual features ảnh hưởng trực tiếp đến hiệu năng và khả năng tổng quát hóa của toàn bộ hệ thống phía sau. Khi không có nhãn để học có giám sát, bài toán trở thành: làm sao tạo ra được visual features đủ mạnh và tổng quát chỉ từ dữ liệu ảnh.

Câu hỏi nghiên cứu cốt lõi mà DINOv2 đặt ra là: liệu self-supervised learning có thể tạo ra các đặc trưng thị giác tổng quát, không cần nhãn, và có thể dùng trực tiếp cho nhiều tác vụ thị giác khác nhau hay không?

1.1.2 Ý nghĩa của Self-Supervised Learning và Foundation Model

Hai khái niệm nền tảng để hiểu DINOv2 là *self-supervised learning* và *foundation model*.

Self-Supervised Learning (SSL). SSL là hướng học biểu diễn trong đó tín hiệu giám sát được *sinh ra từ chính dữ liệu* thay vì từ nhãn do con người gán. Mô hình giải một *pretext task* (nhiệm vụ giả lập) được thiết kế khéo léo để buộc nó học các đặc trưng có ý nghĩa: ví dụ dự đoán phần ảnh bị che từ ngữ cảnh xung quanh, hoặc bắt biểu diễn của các phiên bản biến đổi (augmentation/crop) của cùng một ảnh phải nhất quán với nhau. Vì không cần nhãn, SSL có thể tận dụng kho ảnh khổng lồ không gán nhãn trên internet. Điểm này phân biệt SSL với hai hướng còn lại: học có giám sát (supervised) cần nhãn lớp cho từng ảnh, còn text-guided/weakly-supervised (ví dụ CLIP) cần các cặp ảnh-văn bản đã căn chỉnh.

Foundation Model. Foundation model [7] là mô hình được pretrain trên một lượng dữ liệu rộng và đa dạng ở quy mô lớn, sao cho biểu diễn học được có thể *tái sử dụng và thích ứng* cho nhiều tác vụ downstream khác nhau. Trong thị giác máy tính, một foundation model lý tưởng là một backbone sinh ra đặc trưng tổng quát, dùng được trực tiếp ở trạng thái *frozen* (đóng băng trọng số) chỉ với một head đơn giản phía trên, thay vì phải fine-tuning lại toàn bộ cho mỗi tác vụ. Ý nghĩa thực tiễn rất lớn: chi phí huấn luyện được khấu hao một lần, giảm mạnh nhu cầu dữ liệu gán nhãn, và cho phép tái sử dụng đặc trưng ảnh một cách linh hoạt giống như cách text embedding được dùng phổ biến trong NLP.

Kết nối tới DINOv2. DINOv2 nằm chính tại giao điểm của hai khái niệm trên: nó dùng *self-supervised learning* ở quy mô lớn để xây dựng một *visual foundation model*. Nói cách khác, DINOv2 trả lời cho câu hỏi liệu SSL có đủ mạnh để tạo ra một mô hình nền tảng thị giác cạnh tranh với các phương pháp dựa trên giám sát văn bản hay không.

1.1.3 Hạn chế của các hướng tiếp cận hiện tại

Text-guided pretraining phụ thuộc vào caption

Một hướng phổ biến trong các visual foundation model là huấn luyện mô hình bằng giám sát từ văn bản, chẳng hạn CLIP, OpenCLIP hoặc SWAG. Các mô hình này học cách liên kết ảnh với caption hoặc dữ liệu văn bản đi kèm. Tuy nhiên, cách tiếp cận này có hai hạn chế quan trọng:


- Caption chỉ mô tả một phần nội dung ảnh: văn bản thường tập trung vào ý nghĩa tổng quát của ảnh, trong khi nhiều thông tin thị giác chi tiết như cấu trúc hình học, ranh giới vật thể, texture hoặc quan hệ không gian không được thể hiện đầy đủ.
- Cần dữ liệu ảnh-văn bản đã căn chỉnh: mô hình không thể học linh hoạt từ dữ liệu ảnh thuần túy, trong khi lượng ảnh không có caption chất lượng cao trên internet là rất lớn.

Self-supervised learning trước DINOv2 còn bị giới hạn bởi dữ liệu

Self-supervised learning là một hướng thay thế hấp dẫn vì mô hình học trực tiếp từ ảnh, không cần nhãn hoặc caption. Tuy nhiên, nhiều phương pháp SSL trước đây chủ yếu được phát triển trên ImageNet-1k hoặc ImageNet-22k. Khi mở rộng sang dữ liệu web lớn

hơn nhưng chưa được chọn lọc, chất lượng đặc trưng thường giảm do dữ liệu nhiễu, trùng lặp và mất cân bằng về nội dung.

Vấn đề nằm ở chỗ dữ liệu web thô thường bị chi phối bởi một số nhóm nội dung phổ biến, khiến mô hình dễ học lệch theo các “mode” xuất hiện nhiều thay vì học được biểu diễn đa dạng và tổng quát. Vì vậy, chỉ tăng kích thước dữ liệu là chưa đủ; dữ liệu cần được chọn lọc, khử trùng lặp và cân bằng tốt hơn.



Hình 1.1: Quy trình xử lý dữ liệu của DINOv2: dữ liệu ảnh thô được embedding, khử trùng lặp và truy xuất theo độ tương đồng để tạo tập dữ liệu curated LVD-142M.

Đặc trưng SSL cần đủ mạnh để dùng trực tiếp

Một visual backbone tổng quát không chỉ cần đạt kết quả tốt sau fine-tuning, mà còn phải tạo ra frozen features đủ mạnh để dùng trực tiếp với một head đơn giản. Đây là yêu cầu quan trọng vì fine-tuning cho từng tác vụ làm tăng chi phí tính toán, yêu cầu dữ liệu gán nhãn và làm giảm tính tái sử dụng của mô hình.

1.1.4 Phát biểu bài toán

Từ các hạn chế trên, bài toán trung tâm của DINOv2 có thể được phát biểu như sau: làm thế nào để huấn luyện một mô hình thị giác tự giám sát, trên dữ liệu ảnh lớn nhưng được tuyển chọn tốt, nhằm tạo ra các visual features tổng quát, mạnh và có thể dùng trực tiếp cho nhiều tác vụ khác nhau mà không cần fine-tuning backbone.

Điểm quan trọng của bài toán là DINOv2 không chỉ cải tiến thuật toán học biểu diễn, mà còn nhấn mạnh vai trò quyết định của dữ liệu pretraining. Nói cách khác, chất lượng, độ đa dạng và mức độ cân bằng của dữ liệu là điều kiện then chốt để self-supervised learning có thể trở thành nền tảng cho visual foundation model.


1.2 Động lực nghiên cứu

1.2.1 Tiềm năng chưa được khai thác của self-supervised learning

Thành công của các mô hình ngôn ngữ cho thấy rằng pretraining trên dữ liệu thô với quy mô lớn có thể tạo ra biểu diễn tổng quát, dùng được cho nhiều tác vụ khác nhau. DINOv2 được thúc đẩy bởi câu hỏi tương tự trong thị giác máy tính: nếu mô hình có thể

học từ ảnh thô ở quy mô lớn, liệu nó có thể tạo ra visual features tổng quát như cách language models tạo ra text representations hay không?

Các kết quả trước đó như DINO, MAE và iBOT cho thấy SSL có tiềm năng học được các đặc trưng giàu thông tin. Tuy nhiên, các phương pháp này vẫn chưa chứng minh được một cách thuyết phục rằng frozen features tự giám sát có thể cạnh tranh với các mô hình weakly-supervised trên nhiều nhóm tác vụ thị giác khác nhau.



Hình 1.2: PCA visualization của patch features: các vùng tương ứng giữa những ảnh liên quan được mô hình nhận ra dù thay đổi tư thế, phong cách hoặc đối tượng.

1.2.2 Ba động lực chính dẫn đến DINOv2

Thứ nhất, self-supervised learning có lợi thế vì không phụ thuộc vào nhãn hoặc caption. Nếu học được đặc trưng đủ tốt, mô hình có thể tận dụng lượng ảnh khổng lồ trên internet mà không cần chi phí gán nhãn thủ công hoặc thu thập cặp ảnh-văn bản.

Thứ hai, DINOv2 xuất phát từ nhận định rằng dữ liệu lớn chưa chắc đã tốt nếu không được chọn lọc. Nghiên cứu này xây dựng pipeline tạo tập LVD-142M bằng cách lọc và mở rộng dữ liệu dựa trên độ tương đồng thị giác, thay vì dùng metadata, nhãn hoặc văn bản. Điều này giúp tập dữ liệu vừa lớn, vừa đa dạng, vừa giảm nhiễu.

Thứ ba, mục tiêu của DINOv2 là tạo ra một visual backbone có thể dùng trực tiếp như frozen feature extractor. Nếu thành công, cùng một encoder có thể phục vụ nhiều tác vụ như classification, segmentation, depth estimation, retrieval hoặc video understanding chỉ với một head đơn giản ở phía trên.


Training Data	INet-1k	Im-A	ADE-20k	Oxford-M
INet-22k	85.9	73.5	46.6	62.5
INet-22k \ INet-1k	85.3	70.3	46.2	58.7
Uncurated data	83.3	59.4	48.5	54.3
LVD-142M	85.8	73.9	47.7	64.6

Bảng 1.1: So sánh nguồn dữ liệu pretraining: LVD-142M cho kết quả tốt hơn dữ liệu uncured và thường vượt ImageNet-22k trên nhiều benchmark ngoài ImageNet.

1.2.3 Ý nghĩa của bài toán

Nếu DINOv2 thành công, mô hình sẽ cung cấp một visual foundation backbone có khả năng tái sử dụng cao. Điều này giúp giảm chi phí huấn luyện lại, giảm phụ thuộc vào dữ liệu gán nhãn, đồng thời mở đường cho các hệ thống AI đa phương thức trong đó đặc trưng ảnh có thể được sử dụng linh hoạt giống như biểu diễn văn bản trong NLP.

Kết quả trong bài báo cho thấy khi kết hợp dữ liệu curated, mô hình đủ lớn và recipe huấn luyện ổn định, self-supervised learning có thể thu hẹp khoảng cách với weakly-supervised learning. Đây chính là động lực cốt lõi khiến DINOv2 trở thành một bước tiến quan trọng trong hướng xây dựng visual foundation models không cần giám sát văn bản.



Hình 1.3: Hiệu năng khi scale mô hình: DINOv2 cải thiện mạnh so với các SSL model trước đó và đạt mức cạnh tranh với weakly-supervised features trên nhiều nhóm tác vụ.

1.2.4 Vị trí của DINOv2 trong tiến trình phát triển SSL

Giai đoạn	Đại diện	Đặc điểm chính	Hạn chế trước DINOv2
Instance discrimination	SimCLR, MoCo	Học tương phản ở mức ảnh	Chủ yếu mạnh ở image-level features
SSL với ViT	DINO	Xuất hiện đặc trưng có khả năng phân tách vùng ảnh	Quy mô dữ liệu còn hạn chế
Masked pretraining	MAE	Học biểu diễn thông qua che và tái tạo ảnh	Thường cần fine-tuning để đạt kết quả cao
Patch-level SSL	iBOT	Kết hợp DINO với masked image modeling	Khó scale và phụ thuộc vào dữ liệu nhỏ hơn
DINOv2	DINOv2	Curated data + improved SSL recipe + distillation	Hướng tới frozen features tổng quát

Bảng 1.2: Tiến trình phát triển SSL và vị trí của DINOv2.

Bảng trên cho thấy DINOv2 là điểm hội tụ của nhiều hướng nghiên cứu trước đó. Khác biệt chính của DINOv2 là giải quyết đồng thời hai vấn đề: chất lượng dữ liệu pretraining và khả năng scale thuật toán SSL để tạo ra đặc trưng dùng trực tiếp.

1.3 Phương pháp

Tổng quan phương pháp

DINOv2 không chỉ thay đổi một thành phần đơn lẻ, mà xây dựng một pipeline hoàn chỉnh để học đặc trưng thị giác tổng quát: dữ liệu được tuyển chọn tự động, objective

self-supervised kết hợp giữa mức ảnh và mức patch, các kỹ thuật tối ưu hóa giúp huấn luyện mô hình rất lớn, sau đó distill mô hình lớn thành nhiều backbone nhỏ hơn. Điểm quan trọng là toàn bộ quá trình pretraining không dùng nhãn lớp hay caption văn bản; mô hình học trực tiếp từ ảnh và được đánh giá chủ yếu trong trạng thái frozen features.

Có thể tóm tắt phương pháp của DINOv2 thành năm bước chính. Thứ nhất, nghiên cứu xây dựng tập dữ liệu pretraining LVD-142M từ dữ liệu curated và uncurated thông qua embedding, deduplication và retrieval. Thứ hai, mô hình sử dụng kiến trúc Vision Transformer với cơ chế student-teacher để học biểu diễn ổn định từ nhiều crop khác nhau của cùng một ảnh. Thứ ba, objective học tự giám sát kết hợp DINO loss ở mức ảnh và iBOT loss ở mức patch, giúp đặc trưng học được phù hợp cho cả image-level tasks và dense prediction. Thứ tư, nghiên cứu sử dụng nhiều kỹ thuật tối ưu hóa như Sinkhorn-Knopp centering, KoLeo regularizer, high-resolution adaptation, FlashAttention, sequence packing và FSDP để scale huấn luyện lên mô hình rất lớn. Cuối cùng, mô hình lớn ViT-g/14 được distill sang các backbone nhỏ hơn như ViT-S/14, ViT-B/14 và ViT-L/14 nhằm tạo ra nhiều lựa chọn sử dụng trong thực tế.

Bước 1: Xây dựng dữ liệu pretraining LVD-142M

Thay vì lấy ngẫu nhiên ảnh web thô, nghiên cứu này xây dựng một tập dữ liệu curated quy mô lớn gọi là LVD-142M. Quy trình này bắt đầu từ hai nguồn: một tập curated làm “mỏ neo chất lượng” và một pool uncurated rất lớn lấy từ web. Tập curated gồm các nguồn như ImageNet-22k, ImageNet-1k train split, Google Landmarks và nhiều tập fine-grained; pool uncurated được lọc cơ bản để loại URL không an toàn, nội dung không phù hợp, ảnh trùng lặp theo PCA hash và làm mờ khuôn mặt nhận dạng được.

- **Embedding:** mỗi ảnh được ánh xạ thành vector đặc trưng bằng một self-supervised ViT-H/16 pretrained trên ImageNet-22k. Vector này là cơ sở để đo độ gần nhau giữa các ảnh.
- **Deduplication:** áp dụng copy-detection để loại ảnh gần trùng nhau trong pool uncurated, đồng thời loại các ảnh gần trùng với validation/test set của các benchmark dùng để đánh giá.
- **Retrieval:** với mỗi ảnh trong tập curated, hệ thống tìm các ảnh gần nhất trong pool uncurated bằng cosine similarity. Nếu tập query lớn, lấy khoảng $N = 4$ nearest neighbors; nếu tập nhỏ, lấy mẫu thêm trong cụm tương ứng sau khi clustering.
- **Triển khai:** các bước deduplication và retrieval dùng Faiss với GPU-accelerated indexing. Kết quả cuối cùng là tập LVD-142M gồm 142 triệu ảnh đa dạng và được cân bằng tốt hơn dữ liệu web thô.

Ý nghĩa của bước này là kiểm soát chất lượng và độ đa dạng của dữ liệu. Bài báo cho thấy dữ liệu curated không chỉ giúp tăng hiệu năng trên những benchmark quen thuộc mà còn cải thiện khả năng tổng quát sang các miền không nằm trực tiếp trong quá trình curation.

Bước 2: Kiến trúc mô hình và cơ chế student-teacher

DINOv2 sử dụng họ kiến trúc Vision Transformer (ViT), gồm nhiều kích thước như ViT-S/14, ViT-B/14, ViT-L/14 và ViT-g/14. Trong pretraining, mô hình vận hành theo cơ

chế student-teacher. Student nhận các phiên bản augment/crop khác nhau của cùng một ảnh và được tối ưu bằng gradient descent; teacher không được cập nhật trực tiếp bằng gradient mà là exponential moving average (EMA) của student. Cách này giúp teacher tạo target ổn định hơn, giảm nhiễu trong quá trình học tự giám sát.

Đặc trưng của ViT gồm class token biểu diễn toàn ảnh và patch tokens biểu diễn từng vùng ảnh. Vì vậy DINOv2 tối ưu đồng thời hai loại thông tin: image-level representation và patch-level representation. Đây là lý do đặc trưng của DINOv2 dùng tốt cho cả classification/retrieval lẫn segmentation/depth estimation.

Bước 3: Objective học tự giám sát

Objective của DINOv2 có thể xem là sự kết hợp giữa DINO và iBOT, kèm một số sửa đổi để ổn định khi scale lớn.

Image-level objective theo DINO

DINO loss làm cho class token của student dự đoán phân phối prototype do teacher tạo ra từ một crop khác của cùng ảnh. Class token được đưa qua một DINO head (MLP) để sinh ra vector “prototype scores”; sau softmax, student cho phân phối p_s còn teacher cho phân phối p_t (kèm bước centering, xem bên dưới). Loss chính là cross-entropy giữa hai phân phối:

$$\mathcal{L}_{\text{DINO}} = - \sum p_t \log p_s. \quad (1.1)$$

Ở đây teacher được xây dựng bằng exponential moving average (EMA) của student. Ý nghĩa trực giác: dù nhìn các crop khác nhau của cùng một ảnh, student vẫn phải học biểu diễn ổn định, gần với teacher. Điều này giúp class token trở thành đặc trưng toàn ảnh mạnh.

Patch-level objective theo iBOT

Với iBOT [4], một số patch đầu vào của student bị mask, trong khi teacher vẫn nhìn thấy patch tương ứng. Student phải dự đoán phân phối prototype p_{si} của các patch bị che, sao cho khớp với phân phối p_{ti} mà teacher tạo ra cho chính các patch đó (qua iBOT head và các bước softmax/centering như trên). Loss iBOT là cross-entropy lấy tổng trên tập chỉ số i của các patch bị mask:

$$\mathcal{L}_{\text{iBOT}} = - \sum_i p_{ti} \log p_{si}. \quad (1.2)$$

Thành phần này giúp mô hình học thông tin cục bộ, biên vật thể và cấu trúc không gian, rất quan trọng cho dense prediction như segmentation hoặc depth estimation.

Tách head cho DINO và iBOT

Trong iBOT gốc, DINO head và iBOT head có thể chia sẻ trọng số. Khi scale lên dữ liệu và mô hình lớn, DINOv2 nhận thấy tách riêng hai head cho image-level và patch-level objective hiệu quả hơn, vì hai objective học hai kiểu thông tin khác nhau.

Sinkhorn-Knopp centering

Thay cho bước softmax-centering kèm moving average của DINO, DINOv2 dùng Sinkhorn-Knopp (SK) centering theo SwAV [5] cho output của teacher nhằm tránh collapse và cân bằng việc sử dụng các prototype. Gọi $S \in \mathbb{R}^{B \times K}$ là ma trận prototype scores của teacher trên một batch (B ảnh, K prototype). Khởi tạo $Q = \exp(S/\epsilon)$, sau đó lặp lại 3 lần hai bước chuẩn hóa:

$$Q_{bk} \leftarrow \frac{Q_{bk}}{\sum_{b'} Q_{b'k}} \quad (\text{chuẩn hóa theo cột / prototype}), \quad Q_{bk} \leftarrow \frac{Q_{bk}}{\sum_{k'} Q_{bk'}} \quad (\text{chuẩn hóa theo hàng / ảnh}). \quad (1.3)$$

Kết quả Q xấp xỉ một ma trận doubly-stochastic; mỗi hàng Q_b được dùng làm target p_t cho ảnh tương ứng. Student vẫn dùng softmax thông thường. Cách centering này phân bổ đều việc sử dụng các prototype trong batch, giúp target của teacher ổn định hơn và tránh hiện tượng mọi ảnh dồn về một số ít prototype.

KoLeo regularizer

KoLeo regularizer [6] khuyến khích các vector đặc trưng phân bố đều hơn trong không gian embedding. Với một batch gồm n vector $(x_1, \dots, x_n)$ đã được chuẩn hóa ℓ_2 , KoLeo được định nghĩa qua khoảng cách tối láng giềng gần nhất của mỗi điểm:

$$\mathcal{L}_{\text{koleo}} = -\frac{1}{n} \sum_{i=1}^n \log(d_{n,i}), \quad d_{n,i} = \min_{j \neq i} \|x_i - x_j\|. \quad (1.4)$$

Nếu các đặc trưng bị tụ quá gần nhau thì $d_{n,i}$ nhỏ và regularizer phạt mạnh, do đó mô hình bị thúc đẩy “trải” các embedding ra đều hơn. Vì vậy, KoLeo đặc biệt có ích cho các tác vụ truy xuất ảnh hoặc nearest-neighbor search, nơi khoảng cách giữa embedding rất quan trọng.

Tổng hợp lại, objective huấn luyện kết hợp ba thành phần trên (KoLeo đóng vai trò regularizer với trọng số nhỏ λ):

$$\mathcal{L} = \mathcal{L}_{\text{DINO}} + \mathcal{L}_{\text{iBOT}} + \lambda \mathcal{L}_{\text{koleo}}. \quad (1.5)$$

Toàn bộ một bước huấn luyện tự giám sát của DINOv2, kết hợp các thành phần trên với cơ chế student-teacher và cập nhật EMA, được tóm tắt trong Thuật toán 1.1.

KoLeo	INet-1k	Im-A	ADE-20k	Oxford-M	MIM	INet-1k	Im-A	ADE-20k	Oxford-M
×	85.3	70.6	47.2	55.6	×	85.3	72.0	44.2	64.3
✓	85.8	72.8	47.1	63.9	✓	85.8	72.8	47.1	63.9

(a) Koleo loss

(b) MIM objective in iBOT

Bảng 1.3: Ablation của KoLeo loss và masked image modeling: KoLeo cải thiện retrieval, còn MIM/iBOT giúp cải thiện tác vụ dense prediction như segmentation.

Bước 4: Recipe huấn luyện khi scale lớn

Ngoài objective chính, DINOv2 thêm nhiều thay đổi nhỏ nhưng quan trọng để scale ổn định. Bảng 1.3 cho thấy các thành phần được thêm dần từ iBOT đến DINOv2. Không phải mọi thay đổi đều tăng đồng thời cả k-NN và linear accuracy, nhưng tổng thể chúng giúp quá trình huấn luyện ổn định hơn và tăng chất lượng frozen features.

Thuật toán 1.1 Một bước huấn luyện tự giám sát của DINOv2 (student–teacher)

Đầu vào: ảnh x ; student θ_s và teacher θ_t (gồm backbone ViT, DINO head, iBOT head);
hệ số EMA m ; trọng số λ ; learning rate η

Đầu ra: cập nhật θ_s, θ_t

- 1: Sinh 2 global crops và V local crops từ x bằng augmentation
 - 2: Mask ngẫu nhiên một phần patch cho nhánh student (phục vụ iBOT)
 - 3: Teacher forward 2 global crops; student forward toàn bộ crops
 - 4: $p_t \leftarrow \text{SINKHORNKNOPP}(\text{prototype scores của teacher})$
 - 5: $p_s \leftarrow \text{softmax}(\text{prototype scores của student})$
 - 6: Tính $\mathcal{L}_{\text{DINO}}, \mathcal{L}_{\text{iBOT}}$ (trên các patch bị mask) và $\mathcal{L}_{\text{koleo}}$
 - 7: $\mathcal{L} \leftarrow \mathcal{L}_{\text{DINO}} + \mathcal{L}_{\text{iBOT}} + \lambda \mathcal{L}_{\text{koleo}}$
 - 8: $\theta_s \leftarrow \theta_s - \eta \nabla_{\theta_s} \mathcal{L}$ ▷ cập nhật student bằng gradient descent
 - 9: $\theta_t \leftarrow m \theta_t + (1 - m) \theta_s$ ▷ teacher là EMA của student
-

	INet-1k k-NN	INet-1k linear
iBOT	72.9	82.3
+(our reproduction)	74.5 $\uparrow 1.6$	83.2 $\uparrow 0.9$
+LayerScale, Stochastic Depth	75.4 $\uparrow 0.9$	82.0 $\downarrow 1.2$
+128k prototypes	76.6 $\uparrow 1.2$	81.9 $\downarrow 0.1$
+KoLeo	78.9 $\uparrow 2.3$	82.5 $\uparrow 0.6$
+SwiGLU FFN	78.7 $\downarrow 0.2$	83.1 $\uparrow 0.6$
+Patch size 14	78.9 $\uparrow 0.2$	83.5 $\uparrow 0.4$
+Teacher momentum 0.994	79.4 $\uparrow 0.5$	83.6 $\uparrow 0.1$
+Tweak warmup schedules	80.5 $\uparrow 1.1$	83.8 $\uparrow 0.2$
+Batch size 3k	81.7 $\uparrow 1.2$	84.7 $\uparrow 0.9$
+Sinkhorn-Knopp	81.7 =	84.7 =
+Untying heads = DINOv2	82.0 $\uparrow 0.3$	84.5 $\downarrow 0.2$


Bảng 1.4: Ablation recipe huấn luyện từ iBOT đến DINOv2. Các thay đổi được thêm tuần tự để cải thiện chất lượng đặc trưng và độ ổn định khi scale.

Bước 5: High-resolution adaptation

Các tác vụ mức pixel như segmentation hoặc depth estimation cần giữ lại chi tiết nhỏ trong ảnh. Tuy nhiên, huấn luyện toàn bộ quá trình ở độ phân giải cao rất tốn chi phí. DINOv2 giải quyết bằng cách train phần lớn thời gian ở độ phân giải thấp hơn, sau đó tăng độ phân giải lên 518×518 trong một giai đoạn ngắn cuối pretraining. Cách này gần đạt chất lượng của huấn luyện high-resolution toàn thời gian nhưng tiết kiệm compute hơn nhiều.

Bước 6: Tối ưu triển khai để huấn luyện mô hình lớn

Đóng góp kỹ thuật lớn của DINOv2 nằm ở việc làm cho self-supervised ViT lớn có thể huấn luyện được với chi phí hợp lý. Bài báo nêu rằng với cùng phần cứng, code DINOv2 chạy nhanh khoảng 2 lần và dùng khoảng 1/3 bộ nhớ so với implementation iBOT. Các kỹ thuật chính gồm:



Hình 1.4: Ảnh hưởng của độ phân giải: huấn luyện 224 rồi chuyển sang độ phân giải cao trong giai đoạn ngắn cuối giúp cải thiện cả ImageNet-1k và ADE-20K với chi phí thấp hơn.


- **Fast and memory-efficient attention:** triển khai biến thể FlashAttention để giảm bộ nhớ và tăng tốc self-attention, đặc biệt hữu ích với chuỗi token dài.
- **Sequence packing:** ghép các chuỗi token từ crop lớn và crop nhỏ vào một chuỗi dài, dùng attention mask dạng block-diagonal để ngăn các crop tương tác sai. Cách này tương đương forward riêng từng crop nhưng hiệu quả hơn.
- **Efficient stochastic depth:** thay vì tính residual rồi mask kết quả, hệ thống bỏ qua trực tiếp computation của các residual bị drop, tiết kiệm compute gần tương ứng với drop rate.
- **Fully-Sharded Data Parallel (FSDP):** shard student, teacher và trạng thái optimizer qua nhiều GPU. Điều này giúp train ViT-g hơn 1 tỷ tham số mà không bị giới hạn bởi bộ nhớ một GPU đơn lẻ, đồng thời giảm chi phí truyền thông giữa GPU.

Bước 7: Distillation từ ViT-g sang các model nhỏ

Sau khi huấn luyện mô hình lớn ViT-g/14, DINOv2 không train mọi mô hình nhỏ từ đầu. Thay vào đó, họ distill đặc trưng từ ViT-g sang ViT-S/B/L. Trong distillation, ViT-g đóng vai trò teacher cố định; student nhỏ học để tái tạo output của teacher. Một EMA của student được giữ làm model cuối. Quá trình này giúp các model nhỏ kế thừa chất lượng đặc trưng của mô hình lớn, thường tốt hơn so với train cùng kiến trúc từ scratch.

Bước 8: Giao thức đánh giá

Để chứng minh đặc trưng thật sự tổng quát, DINOv2 chủ yếu đánh giá trong thiết lập frozen backbone. Tức là backbone pretrained được giữ nguyên, chỉ train một linear classifier hoặc một head đơn giản phía trên. Các benchmark bao phủ nhiều cấp độ: classification trên ImageNet và các tập fine-grained, robustness/domain shift, video understanding, retrieval, semantic segmentation và monocular depth estimation. Cách đánh giá này phù hợp với mục tiêu của bài báo: tạo feature extractor dùng trực tiếp, không cần fine-tuning backbone.



(a) Comparison on individual metrics

Arch	Method	INet-1k	Segm.	Depth↓	Classif.
ViT-g/14	Scratch	86.5	73.4	1.00	92.1
ViT-L/14	Scratch	84.5	72.2	1.10	90.2
ViT-L/14	Distill	86.3	73.3	1.08	91.2

Arch	Method	Finegr.	Retrieval	ARSketch	Video
ViT-g/14	Scratch	78.3	75.2	77.0	69.3
ViT-L/14	Scratch	75.8	71.3	69.5	67.3
ViT-L/14	Distill	77.6	76.3	74.5	67.5

(b) Averaged metrics on 8 vision tasks

Hình 1.5: Hiệu quả của distillation: ViT-L/14 distilled từ ViT-g/14 vượt ViT-L/14 train từ scratch trên nhiều benchmark.

1.4 Kết quả

1.4.1 Tổng quan kết quả

Kết quả chính của DINOv2 là self-supervised pretraining, nếu được scale với dữ liệu curated và recipe phù hợp, có thể tạo ra frozen visual features cạnh tranh với các mô hình weakly-supervised/text-guided tốt nhất. Điểm đáng chú ý là DINOv2 mạnh trên cả tác vụ image-level và pixel-level, trong khi nhiều SSL trước đó chỉ mạnh ở một nhóm tác vụ hoặc cần fine-tuning đáng kể.

1.4.2 Kết quả trên ImageNet-1k

Trên ImageNet-1k với linear probe trên frozen features, DINOv2 ViT-g/14 đạt 86.5% top-1 accuracy, cao hơn OpenCLIP ViT-G/14 86.2% và EVA-CLIP ViT-g/14 86.4%. Trên ImageNet-Real, DINOv2 ViT-g/14 đạt 89.6%, và trên ImageNet-V2 đạt 78.4%. Điều này cho thấy DINOv2 không chỉ khớp tốt validation set gốc mà còn tổng quát tốt hơn sang các biến thể đánh giá khác.

Khi fine-tuning backbone trên ImageNet-1k, hiệu năng của ViT-g/14 tăng từ 86.5% lên 88.5% ở độ phân giải 224 và từ 86.7% lên 88.9% ở độ phân giải 448. Mức tăng này cho thấy fine-tuning vẫn giúp cải thiện, nhưng không bắt buộc để đạt hiệu năng cao; frozen features của DINOv2 đã đủ mạnh để dùng trực tiếp.

1.4.3 Robustness và domain generalization

Trên các benchmark domain shift như ImageNet-A, ImageNet-R, ImageNet-C và ImageNet-Sketch, DINOv2 vượt xa các SSL baseline trước đó. Ví dụ, ViT-g/14 đạt 75.9% trên ImageNet-A, trong khi iBOT ViT-L/16 chỉ đạt 41.5%. Với ImageNet-C, chỉ số càng thấp càng tốt, DINOv2 ViT-g/14 đạt 28.2, tốt hơn cả OpenCLIP ViT-G/14 45.3. Điều này chứng minh đặc trưng của DINOv2 không quá phụ thuộc vào phân phối ImageNet chuẩn.

1.4.4 Phân loại ảnh/video ngoài ImageNet

DINOv2 cũng được đánh giá trên các tập fine-grained và video. Với iNaturalist 2018/2021, ViT-g/14 đạt 81.6% và 85.7%, cao hơn OpenCLIP ViT-G/14 lần lượt 73.0% và 76.0%.

Method	Arch.	Data	Text sup.	kNN	linear		
				val	val	ReaL	V2
Weakly supervised							
CLIP	ViT-L/14	WIT-400M	✓	79.8	84.3	88.1	75.3
CLIP	ViT-L/14 ₃₃₆	WIT-400M	✓	80.5	85.3	88.8	75.8
SWAG	ViT-H/14	IG3.6B	✓	82.6	85.7	88.7	77.6
OpenCLIP	ViT-H/14	LAION	✓	81.7	84.4	88.4	75.5
OpenCLIP	ViT-G/14	LAION	✓	83.2	86.2	89.4	77.2
EVA-CLIP	ViT-g/14	custom*	✓	83.5	86.4	89.3	77.4
Self-supervised							
MAE	ViT-H/14	INet-1k	×	49.4	76.6	83.3	64.8
DINO	ViT-S/8	INet-1k	×	78.6	79.2	85.5	68.2
SEERv2	RG10B	IG2B	×	—	79.8	—	—
MSN	ViT-L/7	INet-1k	×	79.2	80.7	86.0	69.7
EsViT	Swin-B/W=14	INet-1k	×	79.4	81.3	87.0	70.4
Mugs	ViT-L/16	INet-1k	×	80.2	82.1	86.9	70.8
iBOT	ViT-L/16	INet-22k	×	72.9	82.3	87.5	72.4
DINOv2	ViT-S/14	LVD-142M	×	79.0	81.1	86.6	70.9
	ViT-B/14	LVD-142M	×	82.1	84.5	88.3	75.1
	ViT-L/14	LVD-142M	×	83.5	86.3	89.5	78.0
	ViT-g/14	LVD-142M	×	83.5	86.5	89.6	78.4

Bảng 1.5: Linear evaluation trên ImageNet-1k: DINOv2 ViT-g/14 đạt 86.5% linear accuracy và cạnh tranh trực tiếp với các mô hình weakly-supervised/text-guided.

Với video, DINOv2 đạt 78.4% trên Kinetics-400 và 91.2% trên UCF-101, ngang hoặc nhỉnh hơn OpenCLIP ở các tập này. Kết quả này đáng chú ý vì DINOv2 không được huấn luyện trực tiếp trên video nhưng đặc trưng ảnh vẫn chuyển giao tốt sang action recognition.

1.4.5 Dense recognition: segmentation và depth estimation

Một điểm mạnh quan trọng của DINOv2 là chất lượng patch-level features. Với semantic segmentation, ViT-g/14 đạt 49.0 mIoU trên ADE20K ở thiết lập linear và 53.0 với multi-scale; trên CityScapes đạt 71.3/81.0; trên Pascal VOC đạt 83.0/86.2. Những con số này cho thấy frozen features của DINOv2 giữ được thông tin cục bộ đủ tốt để tạo mask phân đoạn mà không cần fine-tuning toàn bộ backbone.

Với monocular depth estimation, chỉ số RMSE càng thấp càng tốt. DINOv2 ViT-g/14 đạt 0.344/0.298/0.279 trên NYUd tùy thiết lập, 2.62/2.35/2.11 trên KITTI và 0.402/0.362/0.338 trong thiết lập chuyển miền NYUd $\rightarrow$ SUN RGB-D. Điều này cho thấy patch features chứa thông tin hình học và cấu trúc không gian, dù mô hình không được huấn luyện bằng nhãn độ sâu.

1.4.6 Kết quả định tính

Các ví dụ định tính cho thấy DINOv2 tạo ra segmentation và depth map mượt hơn, ít nhiễu hơn so với OpenCLIP-G trong nhiều trường hợp. Với ảnh ngoài phân phối huấn luyện như tranh, ký họa hoặc ảnh động vật, DINOv2 vẫn có khả năng tách vùng chính

Arch.	Res.	Linear	Finetuned	Δ
ViT-g/14	224	86.5	88.5	+2.0
	448	86.7	88.9	+2.2

Bảng 1.6: Fine-tuning trên ImageNet-1k: DINOv2 vẫn cải thiện khi fine-tune, nhưng mức tăng vừa phải cho thấy frozen features đã rất mạnh.

Method	Arch	Data	Im-A	Im-R	Im-C↓	Sketch
OpenCLIP	ViT-G/14	LAION	63.8	87.8	45.3	66.4
MAE	ViT-H/14	INet-1k	10.2	34.4	61.4	21.9
DINO	ViT-B/8	INet-1k	23.9	37.0	56.6	25.5
iBOT	ViT-L/16	INet-22k	41.5	51.0	43.9	38.5
DINOv2	ViT-S/14	LVD-142M	33.5	53.7	54.4	41.2
	ViT-B/14	LVD-142M	55.1	63.3	42.7	50.6
	ViT-L/14	LVD-142M	71.3	74.4	31.5	59.3
	ViT-g/14	LVD-142M	75.9	78.8	28.2	62.5

Bảng 1.7: Domain generalization: DINOv2 cải thiện mạnh so với SSL trước đó, đặc biệt trên ImageNet-A và ImageNet-C.

và ước lượng cấu trúc không gian hợp lý. Điều này củng cố nhận định rằng đặc trưng học được không chỉ ghi nhớ nhãn lớp mà còn nắm bắt cấu trúc thị giác tổng quát.

1.4.7 Kết luận từ kết quả

Từ các kết quả trên, có thể rút ra ba kết luận. Thứ nhất, self-supervised learning có thể cạnh tranh với weakly-supervised/text-guided pretraining nếu dữ liệu được curated tốt và mô hình được scale đủ lớn. Thứ hai, DINOv2 mạnh không chỉ ở classification mà còn ở các tác vụ dense prediction, chứng tỏ patch-level features có chất lượng cao. Thứ ba, frozen features của DINOv2 đủ mạnh để giảm nhu cầu fine-tuning backbone trong nhiều ứng dụng thực tế.

1.5 Đóng góp

1.5.1 Đóng góp tổng quát

Đóng góp lớn nhất của DINOv2 là chứng minh self-supervised learning có thể tạo ra visual foundation features mạnh, tổng quát và dùng trực tiếp nếu kết hợp đúng ba yếu tố: dữ liệu curated quy mô lớn, recipe huấn luyện ổn định, và triển khai hiệu quả để scale mô hình. Bài báo không chỉ đưa ra một mô hình mới mà còn cung cấp một quy trình hoàn chỉnh để xây dựng backbone thị giác nền tảng.

Feature	Arch	Image classification			Video classification		
		iNat2018	iNat2021	Places205	K400	UCF-101	SSv2
OpenCLIP	ViT-G/14	73.0	76.0	69.8	78.3	90.7	35.8
MAE	ViT-H/14	31.0	32.3	52.4	54.2	70.6	29.2
DINO	ViT-B/8	59.6	68.3	60.4	64.5	85.0	32.6
iBOT	ViT-L/16	66.3	74.6	64.4	72.6	88.6	38.7
DINOv2	ViT-S/14	69	74.2	62.9	67.8	87	33.1
	ViT-B/14	76.4	81.1	66.2	73.2	89.1	34.4
	ViT-L/14	80.4	85.1	67.3	76.3	90.5	35.6
	ViT-g/14	81.6	85.7	67.5	78.4	91.2	38.3

Bảng 1.8: Linear evaluation trên các benchmark phân loại ảnh và video: DINOv2 tổng quát tốt sang fine-grained classification và video understanding.

Method	Arch.	ADE20k (62.9)		CityScapes (86.9)		Pascal VOC (89.0)	
		lin.	+ms	lin.	+ms	lin.	+ms
OpenCLIP	ViT-G/14	39.3	46.0	60.3	70.3	71.4	79.2
MAE	ViT-H/14	33.3	30.7	58.4	61.0	67.6	63.3
DINO	ViT-B/8	31.8	35.2	56.9	66.2	66.4	75.6
iBOT	ViT-L/16	44.6	47.5	64.8	74.5	82.3	84.3
DINOv2	ViT-S/14	44.3	47.2	66.6	77.1	81.1	82.6
	ViT-B/14	47.3	51.3	69.4	80.0	82.5	84.9
	ViT-L/14	47.7	53.1	70.3	80.9	82.1	86.0
	ViT-g/14	49.0	53.0	71.3	81.0	83.0	86.2

Bảng 1.9: Semantic segmentation với frozen features: DINOv2 đạt kết quả mạnh trên ADE20K, CityScapes và Pascal VOC.

1.5.2 Các đóng góp chính

1.5.3 Đóng góp về mặt khoa học

- DINOv2 thay đổi cách nhìn về self-supervised visual pretraining: thay vì cho rằng SSL yếu hơn text-guided pretraining, bài báo cho thấy SSL có thể cạnh tranh nếu dữ liệu và scale được xử lý đúng.
- Bài báo nhấn mạnh vai trò của data curation. Không phải cứ tăng số lượng ảnh là tốt; dữ liệu phải đủ sạch, đa dạng và cân bằng để tránh overfit vào các mode phổ biến của dữ liệu web.
- Bài báo cho thấy một encoder thị giác tốt nên được đánh giá bằng khả năng làm frozen feature extractor trên nhiều tác vụ, không chỉ bằng accuracy sau fine-tuning trên ImageNet.
- DINOv2 kết nối image-level representation và patch-level representation trong cùng một backbone, nhờ đó dùng được cho cả phân loại, truy xuất ảnh, segmentation và

Method	Arch.	NYUd (0.330)			KITTI (2.10)			NYUd $\rightarrow$ SUN RGB-D (0.421)		
		lin. 1	lin. 4	DPT	lin. 1	lin. 4	DPT	lin. 1	lin. 4	DPT
OpenCLIP	ViT-G/14	0.541	0.510	0.414	3.57	3.21	2.56	0.537	0.476	0.408
MAE	ViT-H/14	0.517	0.483	0.415	3.66	3.26	2.59	0.545	0.523	0.506
DINO	ViT-B/8	0.555	0.539	0.492	3.81	3.56	2.74	0.553	0.541	0.520
iBOT	ViT-L/16	0.417	0.387	0.358	3.31	3.07	2.55	0.447	0.435	0.426
DINOv2	ViT-S/14	0.449	0.417	0.356	3.10	2.86	2.34	0.477	0.431	0.409
	ViT-B/14	0.399	0.362	0.317	2.90	2.59	2.23	0.448	0.400	0.377
	ViT-L/14	0.384	0.333	0.293	2.78	2.50	2.14	0.429	0.396	0.360
	ViT-g/14	0.344	0.298	0.279	2.62	2.35	2.11	0.402	0.362	0.338

Bảng 1.10: Depth estimation với frozen features: DINOv2 cải thiện rõ rệt so với OpenCLIP, MAE, DINO và iBOT; chỉ số thấp hơn là tốt hơn.

depth estimation.

1.5.4 Đóng góp về mặt thực tiễn

- Người dùng có thể lấy DINOv2 làm backbone có sẵn, sau đó chỉ cần train một head đơn giản cho tác vụ cụ thể, giúp giảm chi phí compute và dữ liệu gán nhãn.
- Các model có nhiều kích thước, từ nhỏ đến lớn, phù hợp với nhiều điều kiện triển khai khác nhau.
- Vì không cần caption/text trong pretraining, pipeline có thể áp dụng cho những kho ảnh lớn không có nhãn hoặc metadata đáng tin cậy.
- Kết quả tốt trên dense tasks giúp DINOv2 hữu ích cho các ứng dụng yêu cầu hiểu cấu trúc không gian như segmentation, robotics, autonomous driving hoặc phân tích ảnh y tế/hình ảnh chuyên ngành.

1.5.5 Hạn chế và hướng mở rộng

Dù DINOv2 đạt kết quả rất mạnh, bài báo cũng cho thấy vẫn còn một số vấn đề mở. Thứ nhất, mô hình vẫn có bias theo khu vực địa lý và mức thu nhập trong một số đánh giá fairness. Thứ hai, pretraining mô hình lớn tiêu tốn năng lượng đáng kể, nên cần cân nhắc chi phí môi trường. Thứ ba, dù frozen features mạnh, một số tác vụ chuyên biệt vẫn có thể cần fine-tuning hoặc thêm module phù hợp. Các hướng mở rộng tự nhiên gồm kết hợp DINOv2 với language-enabled AI systems, khai thác visual features như “token thị giác”, và tiếp tục scale dữ liệu/mô hình theo hướng an toàn, cân bằng hơn.

1.5.6 Tóm tắt cuối cùng

Tóm lại, DINOv2 đóng góp một bước tiến quan trọng cho visual foundation models: mô hình học không cần supervision, không phụ thuộc vào caption, tạo được đặc trưng tổng quát và có thể dùng trực tiếp trên nhiều tác vụ. Sự thành công của DINOv2 đến từ việc kết hợp chặt chẽ giữa dữ liệu, thuật toán và kỹ thuật hệ thống, thay vì chỉ cải tiến một loss function riêng lẻ.




Figure 7: **Segmentation and depth estimation with linear classifiers.** Examples from ADE20K, NYUd, SUN RGB-D and KITTI with a linear probe on frozen OpenCLIP-G and DINOv2-g features.

Hình 1.6: Kết quả định tính về segmentation và depth estimation với linear classifier trên frozen features.

Tài liệu tham khảo

[1] Maxime Oquab et al., “DINOv2: Learning Robust Visual Features without Supervision”, Transactions on Machine Learning Research, 2024.



Hình 1.7: Ví dụ ngoài phân phối: DINOv2 vẫn cho kết quả tương đối ổn trên tranh, ký họa và ảnh thuộc miền khác.

Nhóm đóng góp	Nội dung	Ý nghĩa
Dữ liệu	Đề xuất pipeline tự động để xây dựng LVD-142M từ curated + uncurated data bằng embedding, deduplication và retrieval.	Giải quyết vấn đề dữ liệu web thô thiếu kiểm soát; cho thấy chất lượng và độ đa dạng dữ liệu là yếu tố quyết định.
Objective SSL	Kết hợp DINO image-level loss và iBOT patch-level loss, dùng separate heads, Sinkhorn-Knopp centering và KoLeo regularizer.	Tạo đặc trưng tốt cho cả image-level tasks và dense pixel-level tasks.
Scale training	Tối ưu implementation bằng memory-efficient attention, sequence packing, efficient stochastic depth và FSDP.	Huấn luyện được ViT-g hơn 1B tham số nhanh hơn và tiết kiệm bộ nhớ hơn so với iBOT.
Model family	Train ViT-g/14 rồi distill sang ViT-S/B/L để tạo nhiều backbone khác nhau.	Cung cấp lựa chọn mô hình theo nhu cầu tài nguyên mà vẫn giữ chất lượng features tốt.
Đánh giá	Benchmark rộng trên classification, robustness, retrieval, segmentation, depth và video understanding.	Chứng minh frozen features tổng quát, không chỉ tốt trên một benchmark đơn lẻ.
Tài nguyên mở	Công bố pretrained models và code để cộng đồng sử dụng/tái huấn luyện.	Tăng khả năng tái lập và thúc đẩy ứng dụng DINOv2 trong các hệ thống CV khác.

Bảng 1.11: Tóm tắt các đóng góp chính của DINOv2.

Chương 2

THỰC NGHIỆM ĐÁNH GIÁ DINOv2

2.1 Bài toán Phân loại ảnh

2.1.1 Mô tả chi tiết tập dữ liệu SkinCancerMNIST (HAM10000)

Để kiểm chứng khả năng trích xuất đặc trưng của DINOv2 trong một miền dữ liệu hẹp và mang tính chuyên môn cao, nhóm nghiên cứu quyết định sử dụng bộ dữ liệu y tế **SkinCancerMNIST (HAM10000)**. Đây là một tập dữ liệu ảnh da liễu nổi tiếng với độ khó cao do các bệnh lý về da thường có màu sắc và kết cấu bề mặt rất giống nhau, đồng thời hình thái tổn thương của cùng một loại bệnh lại có thể thay đổi đa dạng.

Bộ dữ liệu bao gồm tổng cộng 10,015 hình ảnh nội soi da liễu, được thu thập từ nhiều nhóm đối tượng khác nhau nhằm đảm bảo tính đại diện. Các tổn thương da được chia thành 7 lớp bệnh lý chính, bao gồm:

- **Melanoma (MEL):** Khối u ác tính tế bào sắc tố, một trong những dạng ung thư da nguy hiểm nhất.
- **Melanocytic nevus (NV):** Nốt ruồi sắc tố lành tính, chiếm số lượng áp đảo trong tập dữ liệu.
- **Basal cell carcinoma (BCC):** Ung thư biểu mô tế bào đáy.
- **Actinic keratosis (AKIEC):** Dày sừng quang hóa, tổn thương tiền ung thư.
- **Benign keratosis (BKL):** Dày sừng lành tính.
- **Dermatofibroma (DF):** U xơ da lành tính.
- **Vascular lesion (VASC):** Tổn thương mạch máu.

Thách thức lớn nhất khi làm việc với tập dữ liệu này là sự mất cân bằng dữ liệu nghiêm trọng (class imbalance). Lớp bệnh lý NV chiếm hơn 67% tổng số ảnh, trong khi các lớp như DF hay VASC chỉ chiếm một tỷ lệ rất nhỏ (dưới 2%). Sự mất cân bằng này đòi hỏi các mô hình phân loại không chỉ học vẹt theo tần suất xuất hiện của nhãn, mà phải có khả năng hiểu sâu các đặc trưng tinh vi về mặt kết cấu (texture) và cấu trúc không gian (spatial structure) của tổn thương để đưa ra quyết định chính xác. Chính vì vậy, HAM10000 là một bài test lý tưởng để đánh giá xem các đặc trưng "out-of-the-box" của DINOv2 có thực sự tổng quát và mạnh mẽ hay không.

2.1.2 Thiết lập thực nghiệm và Cấu hình so sánh (ViT và DINOv2)

Để có một góc nhìn khách quan về sức mạnh của phương pháp học tự giám sát (Self-Supervised Learning - SSL), thực nghiệm được thiết kế theo phương pháp **Linear Probing**. Phương pháp này đóng băng (freeze) hoàn toàn mạng trích xuất đặc trưng (backbone) và chỉ huấn luyện một lớp phân loại tuyến tính (Linear Head) duy nhất ở cuối. Cách làm này đảm bảo rằng kết quả độ chính xác phản ánh trực tiếp chất lượng của các vector đặc trưng ban đầu mà mạng trích xuất được, thay vì sự tinh chỉnh của kiến trúc mạng trong quá trình huấn luyện.

Thực nghiệm được triển khai với cấu hình so sánh song song như sau:

- **Mô hình kiểm chứng (Baseline) - ViT-B/16:** Đây là kiến trúc Vision Transformer tiêu chuẩn được huấn luyện có giám sát (Supervised Learning) trên bộ dữ liệu khổng lồ ImageNet. Mô hình này đại diện cho phương pháp huấn luyện truyền thống, nơi mạng học cách nhận diện các đặc trưng chủ yếu thông qua nhãn (label) của dữ liệu.
- **Mô hình DINOv2 - dinov2_vitb14:** Sử dụng kiến trúc ViT tương đồng, nhưng được huấn luyện hoàn toàn không giám sát trên tập dữ liệu LVD-142M theo phương pháp DINOv2. Mục tiêu là kiểm chứng xem liệu việc học các biểu diễn hình ảnh thuần túy, không có nhãn, có thể vượt qua hoặc ít nhất là cạnh tranh được với phương pháp có nhãn truyền thống khi áp dụng vào một miền dữ liệu y tế hoàn toàn mới.


Siêu tham số (Hyperparameters) huấn luyện:

- **Kích thước batch (Batch size):** 32, đảm bảo tính toán ổn định gradient trong quá trình lan truyền ngược.
- **Số lượng Epochs tối đa:** 20 epochs. Tuy nhiên, cơ chế **Early Stopping** (với patience=5) được áp dụng để tự động dừng quá trình huấn luyện nếu Loss trên tập Validation không có dấu hiệu giảm, giúp ngăn chặn hiện tượng quá khớp (Overfitting).
- **Thuật toán tối ưu (Optimizer):** Adam Optimizer với tốc độ học (Learning Rate) khởi tạo là 10^{-3} , một mức khá chuẩn cho bài toán Linear Probing.
- **Hàm mất mát (Loss Function):** CrossEntropy Loss, phù hợp cho bài toán phân loại đa lớp.

2.1.3 Kết quả và Đánh giá

Sau quá trình huấn luyện thực tế, cả hai mô hình đều có dấu hiệu hội tụ và cung cấp những hiểu biết quan trọng về chất lượng của các vector đặc trưng. Đồ thị hội tụ và bảng số liệu dưới đây minh họa chi tiết quá trình này.

Như quan sát trên Hình 2.1, mô hình DINOv2 (đường màu đỏ) cho thấy tốc độ hội tụ cực kỳ ổn định và nhanh chóng trong những epoch đầu tiên. Điều này chứng tỏ bộ đặc trưng ban đầu mà DINOv2 cung cấp nhờ phương pháp tự giám sát đã chứa sẵn hàm lượng thông tin tổng quát rất cao, cho phép lớp Linear Head phân tách không gian đa chiều một cách dễ dàng. Mô hình ViT tham chiếu (đường màu xanh) cũng cho thấy sự



Hình 2.1: Tốc độ hội tụ (Validation Loss) của các mô hình trong quá trình huấn luyện

hội tụ tốt nhưng có phần kém ổn định hơn ở các giai đoạn đầu, cho thấy các đặc trưng ImageNet đôi khi gặp phải rào cản domain-shift khi chuyển sang ảnh y tế hẹp.

Bảng 2.1 trình bày kết quả chi tiết thu được sau quá trình kiểm thử trên tập dữ liệu chưa từng thấy (Test set).

Mô hình	Phương pháp	Test Accuracy (%)	Test F1-Score (%)
DINOv2	Linear Probing	80.03	79.47
ViT-B/16	ImageNet Pretrained	82.63	81.65


Bảng 2.1: Bảng tổng hợp kết quả hiệu năng của các mô hình

Về mặt hiệu năng tổng thể (Hình 2.2 và Bảng 2.1), mô hình tham chiếu ViT-B/16 đạt kết quả Test Accuracy 82.63% và F1-Score 81.65%. Trong khi đó, DINOv2 đạt 80.03% Accuracy và 79.47% F1-Score. Dù thấp hơn Baseline khoảng 1.35%, kết quả này của DINOv2 là **đặc biệt ấn tượng** khi xem xét bản chất phương pháp huấn luyện. ViT-B/16 đã được tinh chỉnh qua hàng triệu nhãn dữ liệu của con người, mang sẵn định kiến (bias) mạnh mẽ về việc phân loại hình ảnh. Ngược lại, DINOv2 hoàn toàn "mù" về nhãn lớp trong lúc pretrain, nó tự mò mẫm cấu trúc tương đồng giữa các vùng ảnh. Việc DINOv2 có thể bám đuổi sát sao ViT-B/16 trong một domain hẹp như y tế khẳng định tiềm năng khổng lồ của Self-Supervised Learning trong vai trò một Feature Extractor tổng quát.

2.1.4 Phân tích Ma trận Nhầm lẫn

Để hiểu sâu hơn về hành vi phân loại, ma trận nhầm lẫn (Confusion Matrix) của hai mô hình được trích xuất (Hình 2.3 và Hình 2.4).

Sự mất cân bằng dữ liệu của HAM10000 thể hiện rõ qua các ma trận này: cả hai mô hình đều có khả năng nhận diện xuất sắc lớp NV (Melanocytic nevus) vì đây là lớp chiếm đa số (Majority class). Tuy nhiên, với các lớp có số lượng mẫu ít hơn như DF hay



Hình 2.2: So sánh hiệu năng (Accuracy và F1-Score) trên tập Test

VASC, cả hai mô hình đều bộc lộ điểm yếu và có xu hướng dự đoán nhầm sang lớp NV. Điểm khác biệt nằm ở chỗ, các vùng đặc trưng học từ mức patch (patch-level features) của DINOv2 giúp nó nhận diện một số cấu trúc bề mặt đặc thù khá tốt, nhưng đôi lúc vẫn bị nhiễu bởi các bóng sáng hoặc cấu trúc nang lông trên ảnh nội soi. Trong khi đó, ViT-B/16 có xu hướng bảo thủ hơn nhờ việc học các ranh giới lớp (decision boundary) đã được định hình cứng từ ImageNet.


Tóm lại, thực nghiệm trên SkinCancerMNIST khẳng định sức mạnh "out-of-the-box" của DINOv2. Bằng cách kết hợp DINOv2 với các phương pháp xử lý dữ liệu mất cân bằng (như Focal Loss hoặc Weighted Sampling), hoàn toàn có khả năng nâng cao hiệu suất phân loại y tế mà không cần thiết phải tốn kém nguồn lực gắn nhãn hàng vạn ảnh từ đầu.

2.2 Bài toán Phân đoạn ảnh Zero-Shot

Phân đoạn ảnh (Semantic Segmentation) là bài toán *dense prediction* điển hình, đòi hỏi mô hình không chỉ "nhìn" được toàn bộ ảnh mà còn phải giữ được thông tin không gian (spatial layout) ở từng vị trí pixel. Đây vốn là điểm yếu kinh điển của các phương pháp Self-Supervised Learning trước DINOv2 — vốn chỉ tối ưu trên CLS token (toàn ảnh) nên patch features bị "nén" về phục vụ classification. Nhóm chọn bài toán này để kiểm chứng tuyên bố quan trọng nhất của paper DINOv2: **patch features có thể dùng trực tiếp cho dense task mà không cần huấn luyện thêm.**

2.2.1 Mô tả tập dữ liệu Oxford-IIIT Pet (Trimap)

Tập dữ liệu **Oxford-IIIT Pet** bao gồm 7,349 ảnh thuộc 37 giống chó và mèo khác nhau, kèm theo annotation phân đoạn dạng *trimap* với 3 lớp pixel:



Hình 2.3: Ma trận nhầm lẫn (Confusion Matrix) của mô hình DINOv2 trên tập Test


- **Foreground (pet):** pixel thuộc về con vật chính trong ảnh.
- **Background:** pixel nền (cỏ, nhà, đồ vật xung quanh).
- **Border:** vùng ranh giới mờ giữa con vật và nền, thường rộng vài pixel.

So với các benchmark "nặng" như Pascal VOC hay ADE20K, Oxford-IIIT Pet nhẹ hơn nhiều và rất phù hợp cho thực nghiệm *training-free*: chỉ 3 lớp, kích thước ảnh đa dạng, đối tượng chính thường chiếm vị trí trung tâm. Trong thí nghiệm này, nhóm sử dụng `split test.txt` (chuẩn của Oxford), lấy 10 ảnh đầu làm *reference* và 150 ảnh kế tiếp làm tập đánh giá.

2.2.2 Thiết lập thực nghiệm

Toàn bộ pipeline được cài đặt **training-free**: cả ba mô hình so sánh đều bị *đóng băng hoàn toàn* (không có một gradient nào được tính), chỉ trích xuất *patch tokens* từ block cuối cùng và dùng chúng theo hai cách:

- **Phương pháp 1 — Prototype-based** (có vài reference, không có loss): với mỗi class, lấy mask ground-truth của 10 ảnh reference để chọn ra patch features thuộc về class đó, trung bình hóa và L2-normalize thành *prototype vector*. Khi segment ảnh mới, tính cosine similarity giữa từng patch feature và 3 prototype, upsample về độ phân giải gốc bằng bilinear, rồi $\text{argmax} \rightarrow \text{label map}$.
- **Phương pháp 2 — Spherical KMeans clustering** (hoàn toàn không có nhãn): gom patch features từ 10 ảnh reference, chạy KMeans với $k = 3$ trên đơn vị mặt cầu (centroid L2-normalize sau mỗi vòng). Sau khi cluster, gán `cluster_id` $\rightarrow$ `class_id` bằng *greedy IoU matching* trên chính tập reference (không "nhìn" vào tập eval).



Hình 2.4: Ma trận nhầm lẫn (Confusion Matrix) của mô hình ViT-B/16 trên tập Test

Ba feature extractor được so sánh theo cùng pipeline (chỉ thay backbone):

- **DINOv2-S** (dinov2_vits14, ~21M tham số): mô hình SSL nhẹ nhất của DINOv2.
- **DINOv2-B** (dinov2_vitb14, ~86M tham số): tương đương kích thước với baseline ViT-B/16.
- **ViT-B/16 (IN-1K)** (huấn luyện có giám sát trên ImageNet-1K): baseline đối xứng với §2.1, đại diện cho phương pháp truyền thống.

Cấu hình chung: kích thước ảnh 224×224 (bội số chung của patch 14 và 16), normalize theo ImageNet mean/std, đánh giá trên CPU. **Metrics:** mean IoU (mIoU) và pixel accuracy, kèm IoU phân tách theo từng class. Triển khai chi tiết: `src/zero_shot_seg/evaluate.py`.

2.2.3 Kết quả định lượng


Bảng 2.2 và Hình 2.5 tổng hợp mIoU và pixel accuracy của 6 cấu hình. Hình 2.6 mở rộng theo từng class cho phương pháp Prototype.

Có ba quan sát quan trọng từ các số liệu trên:

- **DINOv2 vượt baseline ViT-B/16 cùng kích thước khoảng 6–7 điểm mIoU** ở cả hai phương pháp (DINOv2-B vs ViT-B/16-IN: 61.90% vs 55.47% ở Prototype, 50.31% vs 43.24% ở Clustering). Đây là khoảng cách rất đáng kể với một bài toán dense, đặc biệt khi xét rằng ViT-B/16 đã được tinh chỉnh trên 1.28M ảnh có nhãn ImageNet còn DINOv2 thì **chưa từng nhìn thấy một nhãn nào**. Khoảng cách này lớn nhất ở class *background* (86.6% vs 78.1% — chênh 8.5 điểm), khẳng định

Backbone	Phương pháp	mIoU (%)	Pixel Acc (%)
DINOv2-S	Prototype	62.39	81.78
DINOv2-B	Prototype	61.90	81.70
ViT-B/16 (IN-1K)	Prototype	55.47	75.46
DINOv2-S	Clustering	49.69	80.19
DINOv2-B	Clustering	50.31	80.84
ViT-B/16 (IN-1K)	Clustering	43.24	74.92


Bảng 2.2: Kết quả zero-shot segmentation trên 150 ảnh test của Oxford-IIIT Pet (10 ảnh reference).



Hình 2.5: So sánh mIoU giữa ba backbone và hai phương pháp training-free.

patch features của DINOv2 mã hóa cấu trúc không gian tốt hơn nhiều so với supervised ViT.

- **DINOv2-S đủ tốt cho dense task nhẹ.** Bất ngờ là phiên bản 21M tham số (DINOv2-S) gần như ngang với phiên bản 86M (DINOv2-B) trên Prototype (62.39% vs 61.90%). Điều này cho thấy với một tập class nhỏ và yêu cầu không quá phức tạp, mô hình SSL nhỏ đã đủ để biểu diễn cấu trúc đối tượng — một tin tốt cho việc triển khai trên thiết bị có tài nguyên hạn chế.
- **Class border là điểm yếu chung** (IoU $\sim$ 30% cho Prototype, 0% cho Clustering). Border vốn là vùng "mơ hồ" rộng 1-2 pixel quanh con vật; ở mức patch grid 16×16 , các pixel border bị "nuốt" vào patch hoặc pet hoặc background nên việc dự đoán đúng class này là rất khó. Đây không phải hạn chế của riêng DINOv2 mà là hệ quả của *patch-level resolution* chung của ViT.



Hình 2.6: IoU theo từng class (pet / background / border) cho phương pháp Prototype.

2.2.4 Phân tích định tính

Hình 2.7 hiển thị 4 ảnh đại diện (2 mIoU cao nhất, 2 thấp nhất theo DINOv2-B Prototype) cùng dự đoán của ba cấu hình chính. Quy ước màu: **đỏ** = pet, **xanh dương** = background, **xanh lá** = border.


Quan sát các overlay trên các ảnh thành công (hàng 1-2, Abyssinian_75 và Abyssinian_77), có thể thấy:

- **DINOv2-B Prototype** bám sát đường viền con vật, phân biệt được cả các chi tiết khó như chân và đuôi.
- **DINOv2-B Clustering** dù không có một nhãn nào vẫn xuất hiện ranh giới rõ nét giữa con vật và nền — bằng chứng cho **object-centric emergence** mà paper DINOv2 nhấn mạnh.
- **ViT-B/16 (IN-1K)** tạo ra mask "nhiều" hơn, vùng đỏ lan tỏa sang nền hoặc bỏ sót các vùng nhỏ. Đây là biểu hiện của *CLS-bias* trong supervised training: gradient từ classification head dồn về CLS token, làm patch tokens mất đi tính nhất quán không gian.

Ở các trường hợp khó (hàng 3-4, Abyssinian_220 ngược sáng và american_bulldog_39 có quả bóng bên cạnh), cả ba mô hình đều gặp khó khăn — quả bóng nâu bị DINOv2 phân vào lớp pet do màu tương đồng. Điều này cho thấy **features chỉ có thể "thấy" những gì xuất hiện trong reference**: nếu reference không có ví dụ về đồ vật cạnh con vật, mô hình sẽ ghép nhầm patch có texture gần giống.

Để nhấn mạnh điểm **emergence** của KMeans (không dùng nhãn), Hình 2.8 so sánh trực tiếp KMeans trên patch features của DINOv2-B và ViT-B/16-IN trên 3 ảnh:

Có thể thấy rõ cluster của DINOv2-B tập trung gọn vào con vật trong khi cluster của ViT-B/16-IN lan tỏa sang nền hoặc bị "vỡ" thành nhiều mảnh nhỏ. Đây là minh chứng định tính bổ sung cho con số 7 điểm mIoU mà DINOv2 ăn đứt baseline.




Hình 2.7: So sánh định tính: Original | Ground truth | DINOv2-B Prototype | DINOv2-B Clustering | ViT-B/16 Prototype.

2.2.5 Kết luận §2.2

Thực nghiệm zero-shot segmentation đã củng cố mạnh mẽ tuyên bố cốt lõi của paper DINOv2: **patch features từ học tự giám sát quy mô lớn có thể dùng trực tiếp cho dense task**, không cần fine-tune, không cần segmentation head, và không cần một mẫu có nhãn nào (ở chế độ clustering). Với cùng pipeline và cùng số tham số, DINOv2 vượt baseline ViT-B/16 supervised khoảng 7 điểm mIoU. Quan trọng hơn, KMeans thuần túy trên patch features của DINOv2 đã tự sinh ra ranh giới đối tượng — một tính chất "emergence" mà supervised ViT không có. Đây là tiền đề trực tiếp cho các ứng dụng segmentation ở chương kế tiếp, đặc biệt trong các miền dữ liệu thiếu nhãn như y tế hay nông nghiệp.

Object-centric emergence từ KMeans — DINOv2 (SSL) vs ViT (IN-1K supervised)



Hình 2.8: KMeans ($k = 3$) trên patch features — DINOv2 (SSL) phân biệt foreground/background rõ rệt hơn ViT-B/16 ImageNet.

Chương 3

ĐÁNH GIÁ VÀ TƯ DUY TÍCH CỰC

3.1 Đánh giá thực nghiệm Phân loại ảnh (§2.1)

3.1.1 Điểm mạnh của phương pháp

Dựa trên kết quả thực nghiệm với tập dữ liệu y tế SkinCancerMNIST, có thể rút ra những điểm mạnh cốt lõi của DINOv2:

- **Đặc trưng "Out-of-the-box" sâu sắc:** Khác với các phương pháp SSL cũ, DINOv2 cung cấp một bộ trọng số cực kỳ chất lượng. Ngay cả khi chưa hề nhìn thấy ảnh nội soi da liễu trong quá trình huấn luyện, mô hình vẫn trích xuất được những vector đặc trưng có khả năng phân tách cao. Điều này giúp lớp Linear Probe hội tụ nhanh chóng và hiệu quả hơn hẳn so với việc tái sử dụng đặc trưng từ mô hình ViT được huấn luyện có giám sát (Supervised) trên ImageNet.
- **Tính tổng quát (Generalization) vượt trội:** Khi so sánh cùng một kiến trúc Vision Transformer, DINOv2 (học không giám sát) tỏ ra vượt trội so với ViT (học có giám sát) trong việc hiểu các chi tiết tinh vi về kết cấu (texture) của tổn thương da. ViT học trên ImageNet thường tập trung vào các đặc trưng nhận diện vật thể lớn (shape bias), do đó khi chuyển sang ảnh y tế, độ biểu diễn đặc trưng không thể sánh bằng sự hiểu biết chi tiết ở mức độ cục bộ (local features) của DINOv2.

3.1.2 Điểm hạn chế và Thất bại

Dù mạnh mẽ, phương pháp vẫn tồn tại những rào cản nhất định:

- **Chi phí huấn luyện ban đầu khổng lồ:** Để có được các đặc trưng "vạn năng", Meta AI đã phải dùng đến hàng ngàn GPU để huấn luyện trên 142 triệu hình ảnh. Do đó, việc tự xây dựng một mô hình tương tự DINOv2 từ đầu đối với các nhóm nghiên cứu nhỏ là bất khả thi.
- **Độ nhạy cảm với dữ liệu ngoài phân phối (Out-of-Distribution):** Mặc dù DINOv2 khá quát hóa rất tốt, nhưng trong các trường hợp cực đoan như ảnh y tế chụp dưới ánh sáng quá yếu hoặc ảnh siêu âm mờ, cấu trúc không gian bị biến dạng hoàn toàn, các đặc trưng của DINOv2 có thể mất tác dụng và dẫn tới phân loại sai (Failure cases).

- **Thiếu khả năng giải thích (Interpretability):** Trong y tế, việc hiểu tại sao mô hình đưa ra quyết định là tối quan trọng. DINOv2 cung cấp các vector đặc trưng dày đặc nhưng lại khó để bác sĩ hiểu được lớp Linear Probe đang tập trung vào vùng nào của tổn thương da nếu không sử dụng thêm các công cụ như Grad-CAM hoặc Attention Maps.

3.2 Đánh giá thực nghiệm Phân đoạn ảnh Zero-Shot (§2.2)

3.2.1 Điểm mạnh của phương pháp

Kết quả zero-shot segmentation trên Oxford-IIIT Pet làm nổi bật những điểm mạnh mà bài toán phân loại đơn thuần ở §2.1 chưa cho phép quan sát được:

- **Patch features đủ mạnh cho dense task mà không cần huấn luyện:** Đây là minh chứng quan trọng nhất cho tuyên bố cốt lõi của paper DINOv2. Toàn bộ pipeline được vận hành *training-free* — không tính bất kỳ gradient nào, không có segmentation head — vậy mà DINOv2-B vẫn đạt 61.90% mIoU theo phương pháp Prototype, vượt baseline ViT-B/16 (cùng kích thước, học có giám sát trên ImageNet) khoảng **7 điểm mIoU**. Khoảng cách này lớn hơn rất nhiều so với chênh lệch $\approx 2.6\%$ ở bài toán phân loại §2.1, phản ánh rằng ưu thế thực sự của DINOv2 nằm ở *chất lượng patch-level features* — thứ mà supervised ViT vốn phải hy sinh khi tối ưu CLS token cho classification.
- **Tính chất "Object-centric emergence":** Khi chạy Spherical KMeans với $k = 3$ trên patch features của DINOv2 mà **không sử dụng bất kỳ nhãn nào**, ranh giới giữa con vật và nền vẫn xuất hiện rõ nét (đạt 50.31% mIoU cho DINOv2-B). Trong khi đó, cluster của ViT-B/16-IN lan tỏa, vỡ thành nhiều mảnh không có ý nghĩa ngữ nghĩa. Đây là tính chất mà supervised ViT không có và là bằng chứng định tính mạnh mẽ cho khả năng "hiểu cấu trúc đối tượng" mà SSL ở quy mô lớn tự sinh ra.
- **Hiệu quả tham số vượt mong đợi:** Mô hình DINOv2-S chỉ với $\sim 21\text{M}$ tham số gần như ngang ngửa DINOv2-B ($\sim 86\text{M}$) ở phương pháp Prototype (62.39% vs 61.90% mIoU). Điều này mở ra khả năng triển khai mô hình SSL cho dense task trên các thiết bị có tài nguyên hạn chế (edge devices, robot), điều rất khó đạt được với các mô hình segmentation chuyên dụng truyền thống.
- **Pipeline rất nhẹ và linh hoạt:** Chỉ cần 10 ảnh reference có nhãn để xây prototype, hoặc thậm chí 0 ảnh có nhãn ở chế độ clustering. So với việc gán nhãn pixel-level cho hàng nghìn ảnh để huấn luyện một U-Net hay Mask R-CNN, đây là sự khác biệt về mặt chi phí ở mức quy mô khác hẳn.

3.2.2 Điểm hạn chế và Thất bại

Tuy nhiên, các thí nghiệm cũng phơi bày một số giới hạn mà chỉ bài toán dense mới làm rõ:

- **Giới hạn độ phân giải ở mức patch:** Class *border* đạt IoU rất thấp ($\sim 30\%$ với Prototype, gần 0% với Clustering). Nguyên nhân nằm ở việc patch grid có kích thước 14×14 hoặc 16×16 pixel, trong khi ranh giới giữa con vật và nền thường chỉ rộng 1-2 pixel. Patch features không thể phân biệt được những vùng mỏng như vậy nếu chỉ upsample bằng bilinear. Đây không phải hạn chế riêng của DINOv2 mà là hệ quả cấu trúc của Vision Transformer, nhưng nó hạn chế trực tiếp khả năng ứng dụng vào các bài toán yêu cầu segment chính xác đường biên (ví dụ: phẫu thuật, đo lường kích thước tổn thương).
- **Phụ thuộc vào chất lượng và phạm vi của reference:** Trong các failure case (american_bulldog_39 có quả bóng nâu bên cạnh), mô hình gán nhầm quả bóng vào lớp *pet* chỉ vì texture và màu sắc tương đồng. Điều này cho thấy DINOv2 "chỉ thấy được những gì đã có trong reference": nếu tập 10 ảnh tham chiếu không chứa bối cảnh phong phú, mô hình sẽ tổng quát hóa kém. Đây là rào cản khi triển khai vào môi trường thực tế nơi cảnh nền cực kỳ đa dạng.
- **Vẫn nhạy cảm với điều kiện chụp khó:** Ảnh ngược sáng (Abyssinian_220) khiến cả ba mô hình đều khó tách foreground/background — chứng tỏ tuy patch features ổn định hơn supervised ViT nhưng chúng vẫn chưa thực sự "bất biến" với ánh sáng và contrast. Trong các ứng dụng y tế hoặc nông nghiệp ngoài trời, đây là yếu tố cần được kiểm soát bằng tiền xử lý hoặc augmentation bổ sung.
- **Phương pháp Clustering vẫn ngầm cần nhãn để gán cluster $\rightarrow$ class:** Dù phần unsupervised đẹp về mặt khái niệm, bước *greedy IoU matching* cuối cùng vẫn dùng mask của 10 ảnh reference để gán nhãn cho cluster. Vì vậy, gọi đây là "hoàn toàn không có nhãn" là không chính xác — đúng hơn nên gọi là *label-efficient*. Trong bài toán thực sự không có một mask ground-truth nào, cần một bước thủ công khác để gán ngữ nghĩa cho từng cluster.
- **Scale-up không tự động cải thiện kết quả:** Bất ngờ là DINOv2-B kém hơn DINOv2-S 0.5 điểm mIoU ở Prototype. Điều này gợi ý rằng việc chọn kích thước mô hình cần dựa trên đặc tính bài toán (số class, độ phức tạp scene), không phải cứ "to hơn là tốt hơn". Việc lựa chọn mô hình SSL phù hợp cho dense task vẫn là một bài toán mở.

3.3 Khả năng áp dụng thực tế

Tổng hợp kết quả từ cả hai thực nghiệm phân loại (§2.1) và phân đoạn zero-shot (§2.2), tính ứng dụng thực tế của DINOv2 trải rộng trên nhiều lĩnh vực:

- **Hỗ trợ Chẩn đoán Y khoa (Medical Imaging):** Dữ liệu y tế (X-quang, MRI, nội soi) rất phong phú nhưng dữ liệu được gán nhãn bởi chuyên gia lại cực kỳ khan hiếm. DINOv2 mở ra tiềm năng kép: (1) phân loại bệnh lý chỉ cần thêm Linear Head với rất ít ảnh có nhãn (như §2.1 đã chứng minh trên SkinCancerMNIST), và (2) phân đoạn tổn thương ở mức zero-shot/few-shot dựa trên một vài ảnh tham chiếu, giảm mạnh thời gian gán nhãn pixel-level vốn cực kỳ tốn kém với bác sĩ.
- **Nông nghiệp thông minh:** Trích xuất đặc trưng của bề mặt lá cây để phát hiện sâu bệnh, phân loại các loại cỏ dại mà không cần tốn công sức thu thập hàng vạn

ảnh gán nhãn cho từng khu vực địa lý. Đặc biệt, khả năng object-centric emergence ở §2.2 cho phép phân đoạn vùng bệnh trên lá chỉ với vài ảnh mẫu — phù hợp cho triển khai trên drone hoặc thiết bị di động ngoài đồng ruộng.

- **Thị giác Robot và Xe tự lái:** Nhờ khả năng phân đoạn ngữ nghĩa (Semantic Segmentation) và bảo toàn cấu trúc không gian cực tốt — được kiểm chứng trực tiếp qua kết quả mIoU vượt trội ở §2.2 — DINOv2 có thể đóng vai trò là "đôi mắt" cốt lõi giúp xe tự lái hoặc robot hiểu sâu sắc về độ sâu và hình học của môi trường xung quanh. Việc DINOv2-S đủ tốt cho dense task càng củng cố tính khả thi trên các hệ thống nhúng (embedded).
- **Tìm kiếm và Truy xuất ảnh (Image Retrieval):** Vector đặc trưng chất lượng cao của DINOv2 có thể được dùng trực tiếp làm cơ sở cho hệ thống tìm kiếm ảnh theo nội dung, gắn kết với các pipeline tìm kiếm ngữ nghĩa trong thương mại điện tử, kho ảnh y tế, hoặc lưu trữ tài sản số (digital asset management).

Tài liệu tham khảo

- [1] Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., ... & Bojanowski, P. (2023). *DINOv2: Learning Robust Visual Features without Supervision*. arXiv preprint arXiv:2304.07193.
- [2] Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., & Joulin, A. (2021). *Emerging properties in self-supervised vision transformers*. In Proceedings of the IEEE/CVF international conference on computer vision (pp. 9650-9660).
- [3] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Houlsby, N. (2020). *An image is worth 16x16 words: Transformers for image recognition at scale*. arXiv preprint arXiv:2010.11929.
- [4] Zhou, J., Wei, C., Wang, H., Shen, W., Xie, C., Yuille, A., & Kong, T. (2022). *iBOT: Image BERT Pre-Training with Online Tokenizer*. In International Conference on Learning Representations (ICLR).
- [5] Caron, M., Misra, I., Mairal, J., Goyal, P., Bojanowski, P., & Joulin, A. (2020). *Unsupervised Learning of Visual Features by Contrasting Cluster Assignments (SwAV)*. In Advances in Neural Information Processing Systems (NeurIPS).
- [6] Sablayrolles, A., Douze, M., Schmid, C., & Jégou, H. (2019). *Spreading vectors for similarity search*. In International Conference on Learning Representations (ICLR).
- [7] Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., ... & Liang, P. (2021). *On the Opportunities and Risks of Foundation Models*. arXiv preprint arXiv:2108.07258.