

DINOv2: Learning Robust Visual Features without Supervision

Báo cáo Thực nghiệm — Môn Thị giác Máy tính

Vũ Minh Hoàng Tùng · Lê Mai Việt Hoàng
Tạ Đình Kiên · Nguyễn Quốc Toàn

Trường Đại học Công nghệ — Đại học Quốc gia Hà Nội
Giảng viên hướng dẫn: PGS. TS Lê Thanh Hà

Hà Nội, 2026

Nội dung trình bày

Lý thuyết

1. Bài toán & Động lực

Bối cảnh, SSL, Foundation Model

2. Phương pháp DINOv2

Dữ liệu, Kiến trúc, Objective, Scale

Thực nghiệm & Đánh giá

3. Thực nghiệm

Phân loại ảnh y tế, Phân đoạn Zero-Shot

4. Đánh giá & Ứng dụng

Điểm mạnh/yếu, Khả năng triển khai

Oquab et al., "DINOv2: Learning Robust Visual Features without Supervision", TMLR 2024



1. Bài toán & Động lực

Bối cảnh: Nghịch lý dữ liệu thị giác

Thực trạng hiện nay

- Ảnh internet: **hàng tỷ**, tăng không ngừng
- Nhãn (label): **khan hiếm**, tốn kém
- Gán nhãn thủ công: **không thể scale**

Hạn chế các hướng tiếp cận

- **Text-guided** (CLIP, OpenCLIP):
Phụ thuộc caption — caption bỏ sót chi tiết thị giác
- **SSL cũ** (DINO, MAE, iBOT):
Chủ yếu test trên ImageNet, yếu khi scale dữ liệu web

Câu hỏi nghiên cứu cốt lõi


“Liệu Self-Supervised Learning có thể tạo ra các visual features tổng quát, không cần nhãn, dùng trực tiếp cho nhiều tác vụ thị giác?”

Yêu cầu đặt ra:

- Mạnh cả **image-level**: classification, retrieval
- Mạnh cả **pixel-level**: segmentation, depth
- Dùng được ở trạng thái **frozen** — không cần fine-tune



Self-Supervised Learning & Foundation Model



Hình 1: PCA visualization của patch features: DINOv2 nhận ra các vùng tương ứng giữa những ảnh liên quan

Self-Supervised Learning (SSL)

- Tín hiệu học được **sinh ra từ chính dữ liệu**
- Giải *pretext task* (không cần nhãn): dự đoán vùng bị che, bắt biểu diễn nhất quán giữa các augmentation
- Tận dụng kho ảnh web khổng lồ không gán nhãn

DINOv2 = SSL ở quy mô lớn



Visual Foundation Model

Không nhãn, không caption — học thuần từ ảnh

dù thay đổi tư thế, phong cách

Foundation Model (Mô hình nền tảng)

- Pretrain **1 lần** trên dữ liệu lớn, đa dạng
- Biểu diễn **tái sử dụng** cho nhiều downstream tasks
- **Frozen backbone** + head đơn giản
- Giống GPT/BERT trong NLP



Tiến trình phát triển SSL & Vị trí của DINOv2

Giai đoạn	Đại diện	Đặc điểm chính	Hạn chế
Instance discrimination	SimCLR, MoCo	Học tương phản mức ảnh	Chỉ mạnh ở image-level
SSL với ViT	DINO	Đặc trưng phân vùng ảnh tự phát	Quy mô dữ liệu hạn chế
Masked pretraining	MAE	Che và tái tạo ảnh	Thường cần fine-tune
Patch-level SSL	iBOT	DINO + masked image modeling	Khó scale, dữ liệu nhỏ
DINOv2	DINOv2	Curated data + SSL recipe + Distillation	Hướng tới frozen features tổng quát

Bảng 1: Tiến trình phát triển SSL và vị trí của DINOv2

Điểm khác biệt

Giải quyết **đồng thời**:
 chất lượng dữ liệu
 + thuật toán SSL
 + kỹ thuật scale


Training Data	INet-1k	Im-A	ADE-20k	Oxford-M
INet-22k	85.9	73.5	46.6	62.5
INet-22k \ INet-1k	85.3	70.3	46.2	58.7
Uncurated data	83.3	59.4	48.5	54.3
LVD-142M	85.8	73.9	47.7	64.6

Bảng 2: So sánh nguồn dữ liệu pretraining:
 LVD-142M cho kết quả vượt trội



2. Phương pháp DINOv2

Tổng quan Pipeline DINOv2



Ràng buộc quan trọng

- **Không** dùng nhãn lớp
- **Không** dùng caption văn bản
- Học thuần từ ảnh thô

Mục tiêu đầu ra


- Frozen backbone dùng ngay
- Tốt cả image & patch level
- Family: ViT-S/B/L/g

Đánh giá chính

- Linear probe (frozen)
- Nhiều benchmark:
classification, segmentation,
depth, video



Bước 1: Xây dựng dữ liệu LVD-142M



Hình 2: Quy trình xử lý: ảnh thô → embedding → dedup → retrieval → LVD-142M

Vấn đề dữ liệu web thô

- Nhiều, trùng lặp nhiều
- Mất cân bằng nội dung
- Không kiểm soát được chất lượng

Pipeline 3 bước:

- 1 **Embedding:** ViT-H/16 → vector đặc trưng mỗi ảnh
- 2 **Deduplication:** loại ảnh gần trùng bằng PCA hash + copy detection
- 3 **Retrieval:** tìm k -NN gần nhất từ tập curated



Bước 2: Kiến trúc ViT & Cơ chế Student–Teacher

Vision Transformer (ViT)

- Ảnh → **patch tokens**: biểu diễn từng vùng 14×14 px
- **CLS token**: biểu diễn tổng quát toàn ảnh
- 4 kích thước: ViT-**S/B/L/g** với patch size 14

CLS token vs Patch tokens

CLS token → classification, retrieval

Patch tokens → segmentation, depth

DINOv2 tối ưu **cả hai loại** trong cùng một backbone

Cơ chế Student–Teacher

- **Student**: nhận nhiều crops khác nhau → cập nhật bằng gradient
- **Teacher**: EMA của student → tạo target ổn định

$$\theta_t \leftarrow m\theta_t + (1 - m)\theta_s$$

- Không có gradient nào chạy qua teacher

Trực giác

Dù nhìn các crop **khác nhau** của cùng một ảnh, student phải học biểu diễn **nhất quán** — teacher làm “giám khảo” ổn định

Bước 3: Objective Huấn luyện Tự giám sát

DINO Loss (Image-level)

- CLS token student khớp với teacher
- Cross-entropy p_s vs p_t
- Sinkhorn-Knopp centering

$$\mathcal{L}_{\text{DINO}} = - \sum p_t \log p_s$$

iBOT Loss (Patch-level)

- Mask ngẫu nhiên các patch của student
- Student đoán phân phối patch bị che
- Head **tách biệt** với DINO head

$$\mathcal{L}_{\text{iBOT}} = - \sum_i p_{ti} \log p_{si}$$

KoLeo Regularizer

- Trải đều embedding trong không gian
- Phạt khi features tụ quá gần nhau
- Hữu ích cho retrieval tasks

$$\mathcal{L}_{\text{koleo}} = - \frac{1}{n} \sum_i \log d_{n,i}$$

$$\mathcal{L} = \mathcal{L}_{\text{DINO}} + \mathcal{L}_{\text{iBOT}} + \lambda \mathcal{L}_{\text{koleo}}$$

Image-level + patch-level trong cùng backbone

KoLeo	INet-1k	Im-A	ADE-20k	Oxford-M
×	85.3	70.6	47.2	55.6
✓	85.8	72.8	47.1	63.9

(a) Koleo loss

MIM	INet-1k	Im-A	ADE-20k	Oxford-M
×	85.3	72.0	44.2	64.3
✓	85.8	72.8	47.1	63.9

(b) MIM objective in iBOT

Bảng 3: Ablation: KoLeo cải thiện retrieval; iBOT/MIM giúp dense prediction như segmentation



Bước 4: Scale & Kỹ thuật Triển khai

Kỹ thuật tối ưu bộ nhớ & tốc độ


- **FlashAttention**: attention tiết kiệm bộ nhớ, tăng tốc self-attention trên chuỗi dài
- **Sequence Packing**: ghép nhiều crop vào một chuỗi dài, block-diagonal attention mask
- **Efficient Stochastic Depth**: bỏ qua trực tiếp computation của residual bị drop
- **FSDP**: shard model + optimizer qua nhiều GPU, train được ViT-g >1B params

Hiệu quả so với iBOT baseline

Nhanh gấp **2×** Tiết kiệm **3×** bộ nhớ GPU

High-Resolution Adaptation

- Train chủ yếu ở 224×224
- Giai đoạn ngắn cuối: **518×518**
- Chi phí thấp, gần đạt chất lượng full high-res




Hình

3: Chuyển sang 518px cuối pretraining: cải thiện cả ImageNet-1k và ADE20K với ít compute hơn



Bước 5: Distillation — Xây dựng Model Family



(a) Comparison on individual metrics

Arch	Method	INet-1k	Segm.	Depth↓	Classif.
ViT-g/14	Scratch	86.5	73.4	1.00	92.1
ViT-L/14	Scratch	84.5	72.2	1.10	90.2
ViT-L/14	Distill	86.3	73.3	1.08	91.2

Arch	Method	Finegr.	Retriev.	ARSketch	Video
ViT-g/14	Scratch	78.3	75.2	77.0	69.3
ViT-L/14	Scratch	75.8	71.3	69.5	67.3
ViT-L/14	Distill	77.6	76.3	74.5	67.5

(b) Averaged metrics on 8 vision tasks

Tại sao cần Distillation?

- Train từng kích thước từ đầu: **rất tốn kém**
- Distillation: model nhỏ **kế thừa chất lượng** từ ViT-g/14
- ViT-g/14 (teacher cố định) → student học tái tạo output của teacher
- EMA của student được giữ làm model cuối


Hình 4: ViT-L/14 distilled từ ViT-g/14 vượt ViT-L/14 train từ scratch trên nhiều benchmark

Kết quả nổi bật

ViT-L/14 **distilled** luôn vượt ViT-L/14 **train từ đầu** → distillation không chỉ tiết kiệm compute mà còn **cải thiện chất lượng**



Kết quả từ Paper: DINOv2 so với SOTA



Hình 5: Scaling performance: DINOv2

cải thiện mạnh theo kích thước model, đạt mức cạnh tranh với weakly-supervised

Method	Arch.	Data	Test sup.	DINO		SOTA	
				val	test	val	test
Weakly supervised							
CLIP	ViT-L/14	ViT-g/14	✓	75.9	84.3	85.1	75.3
CLIP	ViT-L/14	ViT-g/14	✓	80.3	86.2	85.4	75.8
OpenCLIP	ViT-L/14	ViT-g/14	✓	82.4	85.7	85.7	77.8
OpenCLIP	ViT-L/14	ViT-g/14	✓	81.7	84.4	85.4	75.3
EVA-CLIP	ViT-L/14	ViT-g/14	✓	83.2	86.2	85.4	77.2
EVA-CLIP	ViT-g/14	ViT-g/14	✓	85.6	86.1	85.3	77.4
Self-supervised							
MAE	ViT-L/14	Dist-14	×	49.1	76.8	53.2	81.8
SE3Dv2	ViT-L/14	Dist-14	×	75.4	79.2	85.3	86.2
SE3Dv2	ViT-L/14	Dist-14	×	79.2	79.8	85.3	86.2
EViT	ViT-L/14	Dist-14	×	79.1	81.3	87.8	90.4
Map	ViT-L/14	Dist-14	×	80.2	82.1	86.9	90.8
DOT	ViT-L/14	Dist-14	×	73.9	81.3	87.3	92.4
DINOv2							
DINOv2	ViT-L/14	Dist-14	×	79.8	81.1	86.8	90.8
DINOv2	ViT-L/14	Dist-14	×	83.1	84.5	85.3	75.3
DINOv2	ViT-g/14	Dist-14	×	85.6	86.2	85.3	78.8
DINOv2	ViT-g/14	Dist-14	×	85.8	86.4	86.0	79.4

Bảng 4: Linear evaluation ImageNet-1k: DINOv2 ViT-g đạt 86.5%,

ngang OpenCLIP và EVA-CLIP

Kết quả chính (Frozen backbone)

Benchmark	DINOv2-g
ImageNet-1k (linear)	86.5%
ImageNet-A	75.9%
iNaturalist 2021	85.7%
Kinetics-400	78.4%
ADE20K (mIoU)	49.0
NYUd depth (RMSE)	0.344



Kết luận từ paper

3. Thực nghiệm

Thực nghiệm 1: Phân loại ảnh Y tế

Bộ dữ liệu: SkinCancerMNIST (HAM10000)

- **10,015 ảnh** nội soi da liễu
- **7 lớp bệnh lý:** MEL, NV, BCC, AKIEC, BKL, DF, VASC
- Thách thức: **mất cân bằng nghiêm trọng**
NV >67% DF/VASC <2%
- Domain hoàn toàn mới với cả hai model

Siêu tham số

Batch size: 32
 Max epochs: 20 + Early Stopping (patience=5)
 Optimizer: Adam, LR = 10^{-3}
 Loss: CrossEntropy

Phương pháp: Linear Probing


- **Đóng băng hoàn toàn** backbone
- Chỉ train **1 Linear Head** phía trên
- $\Rightarrow$ Đo trực tiếp **chất lượng features**

Cấu hình so sánh:


Model	Pretrain
ViT-B/16	Supervised trên ImageNet-1k (có nhãn)
DINOv2-ViT-B/14	Self-supervised trên LVD-142M (không nhãn)



TN1: Kết quả Phân loại ảnh



Hình 6: Tốc độ hội tụ (Validation Loss): DINOv2 (đỏ) ổn định và nhanh hơn từ đầu



Hình 7: So sánh Accuracy và F1-Score trên tập Test

Kết quả trên tập Test


Model	Accuracy	F1-Score
ViT-B/16 (supervised)	82.63%	81.65%
DINOv2 (SSL)	80.03%	79.47%

Nhận xét quan trọng

- Chênh lệch chỉ $\approx 2.6\%$ mặc dù DINOv2 **chưa từng thấy nhãn nào** khi pretrain
- DINOv2 hội tụ nhanh hơn và ổn định hơn trên domain mới (ảnh y tế)
- ViT-B/16 bị *domain-shift*: shape bias học từ ImageNet

TN1: Phân tích Ma trận Nhầm lẫn


DINOv2 (Self-Supervised)



Hình 8: Ma trận nhầm lẫn của DINOv2 (Self-Supervised)

Điểm chung: Nhận diện tốt **NV** (majority),
DINOv2: Patch features tốt cho texture cục bộ,
ViT-B/16: Decision boundary cứng từ ImageNet

ViT-B/16 (ImageNet Supervised)



Hình 9: Ma trận nhầm lẫn của ViT-B/16 (ImageNet Supervised)

yếu với **DF**, **VASC** (minority)
 bị nhiễu bởi bóng sáng / lông
 → conservative hơn

Thực nghiệm 2: Phân đoạn Zero-Shot

Bộ dữ liệu: Oxford-IIIT Pet

- 7,349 ảnh chó/mèo, 37 giống
- Annotation **trimap** 3 lớp:
■ **pet** / ■ **background** / ■ **border**
- Split: **10** ảnh reference, **150** ảnh eval

Phương pháp 1: Prototype-based

10 ảnh reference $\rightarrow$ prototype vector mỗi class $\rightarrow$ cosine similarity $\rightarrow$ argmax
 Chỉ cần **10 ảnh có nhãn**

Phương pháp 2: Spherical KMeans

Clustering patch features ($k=3$) $\rightarrow$ greedy IoU matching
Không cần nhãn pixel-level nào

Thiết lập: Hoàn toàn Training-free


- Không tính một gradient nào
- Chỉ dùng **patch tokens** (frozen)
- Kiểm tra tuyên bố cốt lõi của paper: patch features đủ mạnh cho dense task

3 Backbone so sánh (cùng pipeline):


Backbone	Params	Pretrain
DINOv2-S	$\sim 21\text{M}$	SSL
DINOv2-B	$\sim 86\text{M}$	SSL
ViT-B/16 IN-1K	$\sim 86\text{M}$	Supervised



TN2: Kết quả Zero-Shot Segmentation



Hình 10: So sánh mIoU: DINOv2 luôn vượt ViT-B/16



Hình 11: IoU theo từng class

ở cả hai phương pháp

(Prototype): border là điểm yếu chung

Backbone	Method	mIoU	Pix.Acc
DINOv2-S	Proto	62.39	81.78
DINOv2-B	Proto	61.90	81.70
ViT-B/16	Proto	55.47	75.46
DINOv2-S	KMeans	49.69	80.19
DINOv2-B	KMeans	50.31	80.84
ViT-B/16	KMeans	43.24	74.92


Bảng 5: Kết

quả Zero-Shot Segmentation trên Oxford-IIIT Pet

3 quan sát quan trọng

- DINOv2 **+7 điểm mIoU** so với ViT cùng kích thước — khoảng cách lớn hơn nhiều so với TN1
- DINOv2-S (21M) $\approx$ DINOv2-B (86M): nhỏ đủ tốt cho dense task nhẹ
- Class *border* yếu ($\sim 30\%$): giới hạn của patch resolution 14×14

TN2: Phân tích Định tính & Tính chất Emergence



Hình 12: Từ trái: Original | Ground truth |

DINOv2-B Prototype | DINOv2-B KMeans | ViT-B/16 Prototype



Hình 13: KMeans ($k=3$): DINOv2 phân biệt

foreground/background tự nhiên; ViT-B/16 bị "vỡ" thành nhiều mảnh

Object-centric emergence

DINOv2 **không dùng nhãn nào** vẫn sinh ra ranh giới đối tượng rõ nét — tính chất tự phát từ SSL quy mô lớn

Failure case

Quả bóng nâu bị nhầm vào lớp *pet* do texture

4. Đánh giá & Ứng dụng

Đánh giá Tổng hợp: Điểm mạnh & Hạn chế

Điểm mạnh

- **Out-of-the-box features** mạnh: linear probe hội tụ nhanh trên domain mới
- **Patch features** chất lượng cao: dense task không cần gradient
- **Object-centric emergence**: clustering tự phát sinh ranh giới đối tượng
- **DINOv2-S đủ tốt**: 21M params, phù hợp thiết bị hạn chế tài nguyên
- Pipeline **rất nhẹ**: few-shot (10 ảnh) hoặc zero-shot (clustering)

Hạn chế

- **Chi phí pretrain**: hàng nghìn GPU-hours — không thể tái tạo độc lập
- **Patch resolution**: class *border* IoU thấp — không phân giải pixel-level
- **Thiếu interpretability**: cần Grad-CAM / Attention Maps cho ứng dụng y tế
- **Phụ thuộc reference**: reference không đa dạng → tổng quát hóa kém
- **Bias dữ liệu**: web data có bias địa lý và nhân khẩu học



Khả năng Ứng dụng Thực tế

Y tế (Medical Imaging)

- Phân loại bệnh lý với rất ít nhãn (few-shot linear probe)
- Phân đoạn tổn thương zero-shot từ vài ảnh mẫu
- Giảm mạnh chi phí gán nhãn pixel-level bởi chuyên gia
- Đã kiểm chứng: *SkinCancerMNIST 80% accuracy không nhãn pretrain*

Nông nghiệp thông minh

- Phát hiện sâu bệnh trên lá từ ảnh drone
- Phân đoạn vùng bệnh với rất ít mẫu
- DINOv2-S phù hợp triển khai trên thiết bị di động, edge devices

Xe tự lái / Robot

- Segmentation ngữ nghĩa không cần fine-tune
- Depth estimation từ frozen patch features
- Hiểu cấu trúc không gian phức tạp
- DINOv2-S phù hợp cho embedded systems

Tìm kiếm & Truy xuất ảnh

- CLS features + KoLeo → semantic search chất lượng cao
- Ứng dụng: e-commerce, digital asset management, kho ảnh y tế
- Không cần gán nhãn, dùng ngay frozen embedding



Kết luận

Những điều DINOv2 chứng minh được

- ① **SSL có thể cạnh tranh với weakly-supervised learning** nếu dữ liệu curated tốt và scale đủ lớn — xóa bỏ quan niệm SSL kém hơn text-guided pretraining
- ② **Patch-level features từ SSL** chứa thông tin không gian đủ mạnh cho dense tasks (segmentation, depth) mà không cần fine-tune backbone
- ③ **Object-centric emergence**: đặc tính tự phát giúp clustering không nhãn vẫn tạo ra ranh giới đối tượng rõ nét
- ④ **Frozen visual foundation model** không phụ thuộc caption/nhãn — tiền đề cho AI đa phương thức thể hệ tiếp theo

Công thức thành công của DINOv2:

Dữ liệu curated + SSL recipe ổn định + Scale hiệu quả



Cảm ơn thầy/cô và các bạn đã lắng nghe!